ANALYSE DE RADIOGRAPHIES PULMONAIRES COVID-19

Rapport d'exploration, préprocessing et modélisation

Projet fil rouge - Formation Data Scientist

Version de finalisation — 9 novembre 2026

Équipe projet : R / K

À compléter lors de la validation finale

Sommaire

1. Introduction au projet

2. Exploration et compréhension des données

3. Préprocessing

4. Modélisation

5. Résultats et comparaison des expériences binaires

6. Résultats et comparaison des expériences multiclasses

7. Comparaison globale — détection de la classe COVID

8. Sélection des modèles approfondis

8. Optimisation des modèles

9. Interprétabilité des modèles — Grad-CAM

10. Évaluation finale sur le jeu de test

11. Discussion et limites

12. Conclusion et perspectives

13. Références et traçabilité des expériences

1. Introduction au projet

1.1 Contexte et problématique

Le projet porte sur l'analyse de radiographies pulmonaires afin de distinguer les cas COVID des cas Non-COVID. Il s'inscrit dans une problématique de classification supervisée d'images médicales et mobilise des techniques de Deep Learning adaptées à l'extraction de motifs visuels locaux.

À compléter lors de la validation finale

1.2 Objectifs

L'objectif principal est de construire et comparer plusieurs stratégies de classification binaire de radiographies thoraciques, en accordant une attention particulière à la détection des cas COVID et aux erreurs de classification.

À compléter lors de la validation finale

2. Exploration et compréhension des données

2.1 Jeu de données et structure

Le dataset initial comporte quatre classes : COVID, Normal, Lung Opacity et Viral Pneumonia. L'exploration a porté sur la structure, la qualité et les principales caractéristiques des images avant prétraitement.

À compléter lors de la validation finale

2.2 Répartition des classes

L'analyse de la distribution met en évidence un déséquilibre dès le dataset initial : COVID 3 616 images (17,08 %), Lung Opacity 6 012 (28,41 %), Normal 10 192 (48,15 %) et Viral Pneumonia 1 345 (6,35 %). Après définition de la cible binaire, les images COVID représentent 3 616 observations (17,08 %) et les images Non-COVID 17 549 observations (82,92 %).

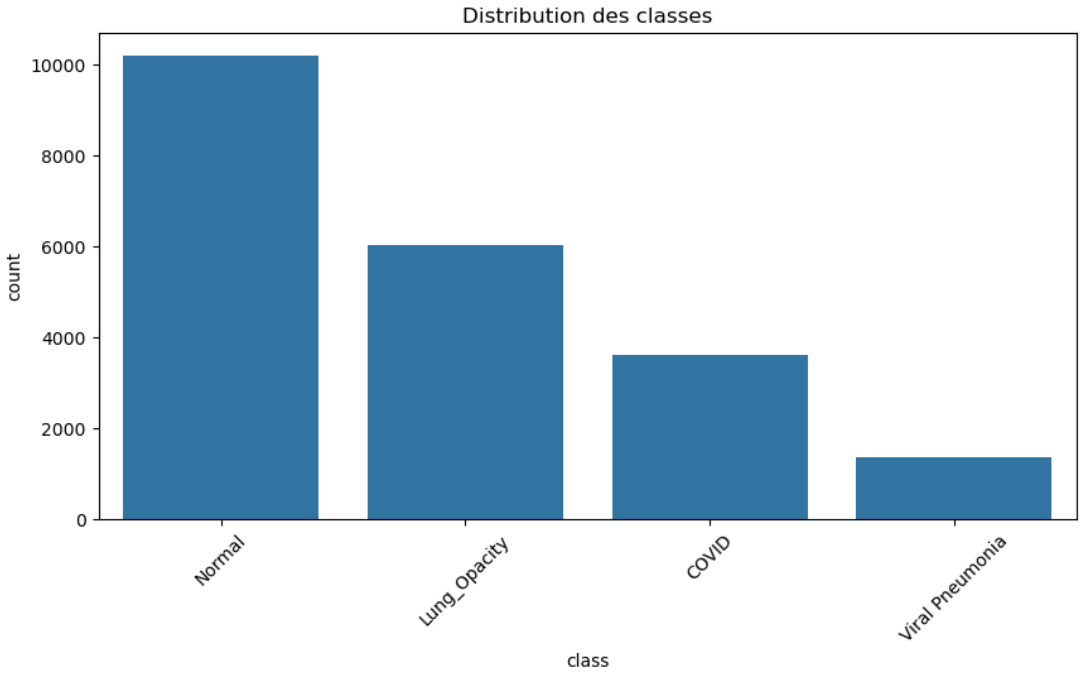


Figure 1 - Répartition des quatre classes du dataset initial.

Le dataset est déséquilibré dès l'exploration, avec une forte prédominance de la classe Normal.

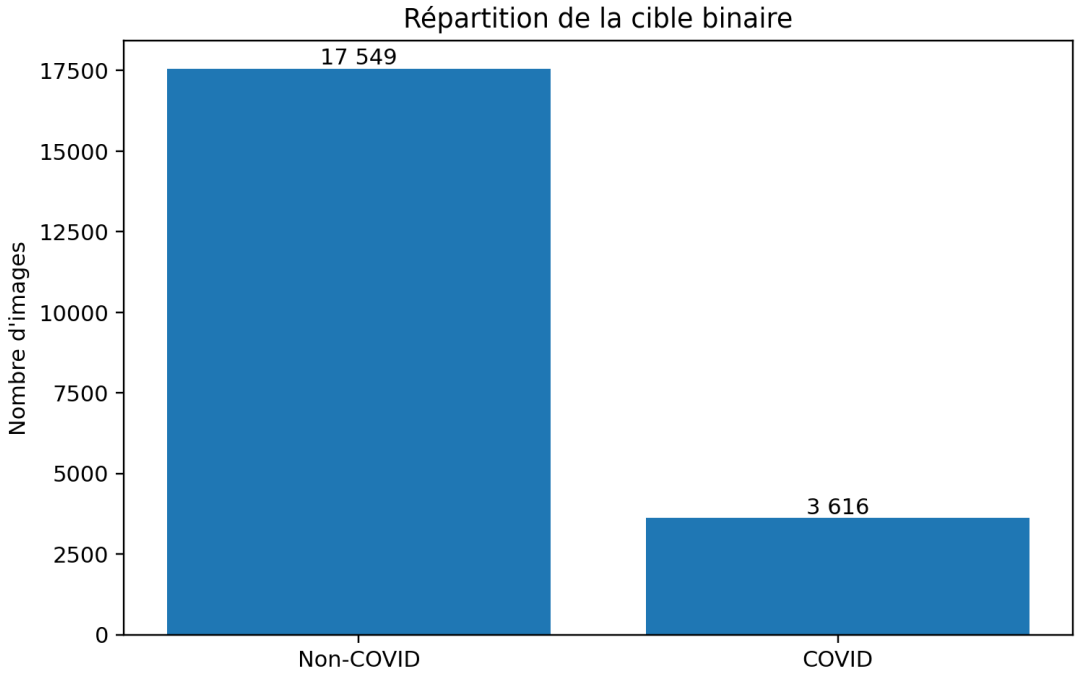


Figure 2 - Répartition de la cible binaire COVID / Non-COVID.

Le regroupement en cible binaire accentue le déséquilibre : les cas COVID représentent 17,08 % des images.

2.3 Qualité et structure des images

Les visualisations réalisées sur plusieurs échantillons montrent que les images sont globalement exploitables. Le parcours automatisé des 21 165 images n'a détecté aucun fichier corrompu. Les dimensions sont totalement homogènes : 21 165 images sur 21 165 mesurent 299 × 299 pixels (largeur et hauteur min., max. et moyenne = 299).

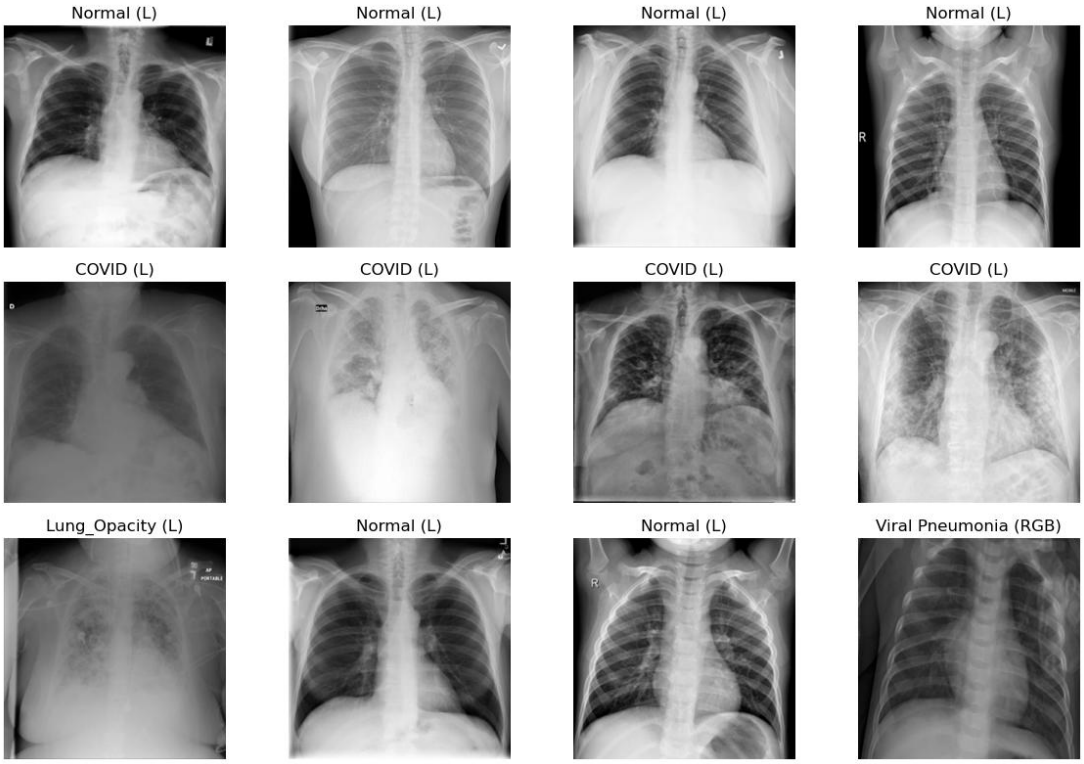


Figure 3 - Échantillon de radiographies issues des différentes classes.

L'inspection visuelle confirme une variabilité importante des images tout en montrant des structures pulmonaires globalement exploitables.

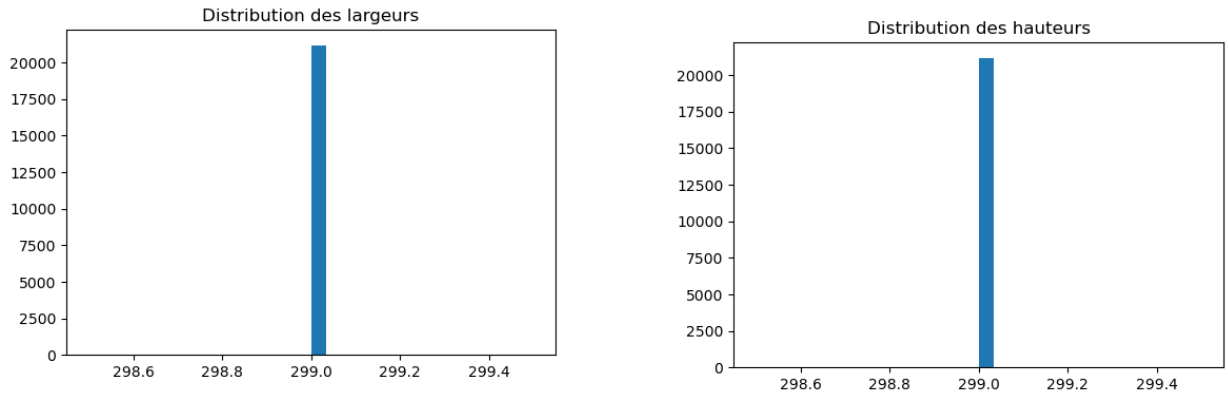


Figure 4 — Distribution des largeurs (gauche) et des hauteurs (droite) des radiographies.

Les dimensions sont homogènes, ce qui simplifie le redimensionnement commun avant modélisation.

2.4 Analyse des canaux

L'analyse des modes recense 21 025 images en niveaux de gris (mode L), soit environ 99,34 % du dataset, et 140 images RGB (0,66 %). Cette hétérogénéité, bien que minoritaire, impose une harmonisation des canaux adaptée à la famille de modèle utilisée.

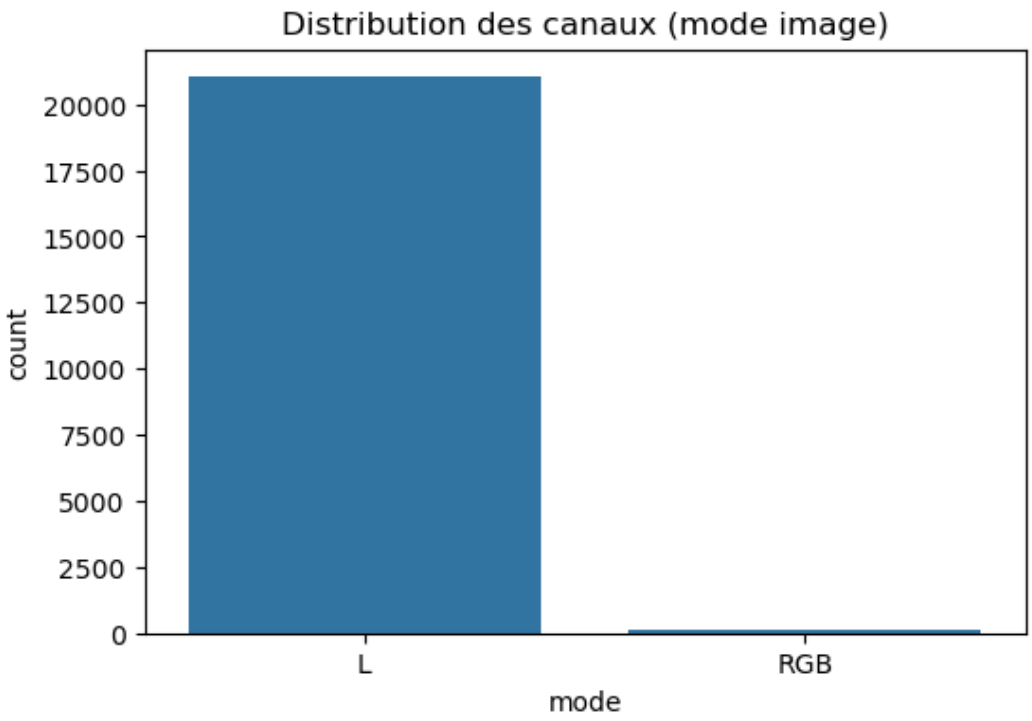


Figure 5 - Distribution des modes d'image.

La très grande majorité des images est en niveaux de gris, mais la présence d'images RGB justifie une harmonisation des canaux.

2.5 Intensité, contraste et images atypiques

L'analyse de l'intensité moyenne et du contraste a identifié quelques images atypiques. Les statistiques par classe confirment néanmoins un fort chevauchement : l'intensité moyenne vaut 139,52 ± 25,03 pour COVID, 126,02 ± 23,57 pour Lung Opacity, 129,39 ± 22,45 pour Normal et 125,37 ± 18,98 pour Viral Pneumonia. Le contraste moyen vaut respectivement 54,65 ± 14,83, 57,40 ± 9,81, 61,56 ± 9,55 et 58,75 ± 10,78. Ces caractéristiques globales ne permettent donc pas, à elles seules, de séparer nettement les pathologies.

L'inspection des extrêmes a porté notamment sur les 12 images les plus sombres et les 12 images au plus faible contraste. Ces observations ne révélant pas à elles seules de défaut justifiant leur exclusion, ces images ont été conservées afin de ne pas supprimer artificiellement des cas potentiellement représentatifs de la variabilité réelle du dataset.

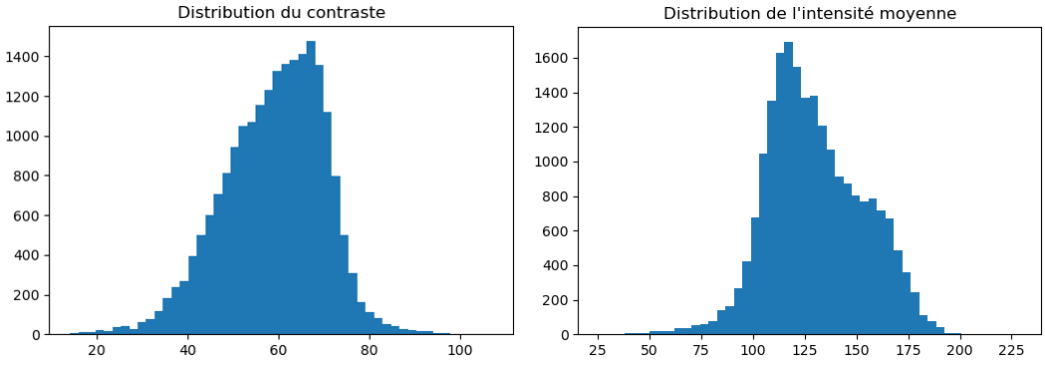


Figure 6 - Distributions du contraste et de l'intensité moyenne.

Les distributions mettent en évidence quelques valeurs atypiques, sans séparation nette des classes à partir de ces seuls indicateurs.

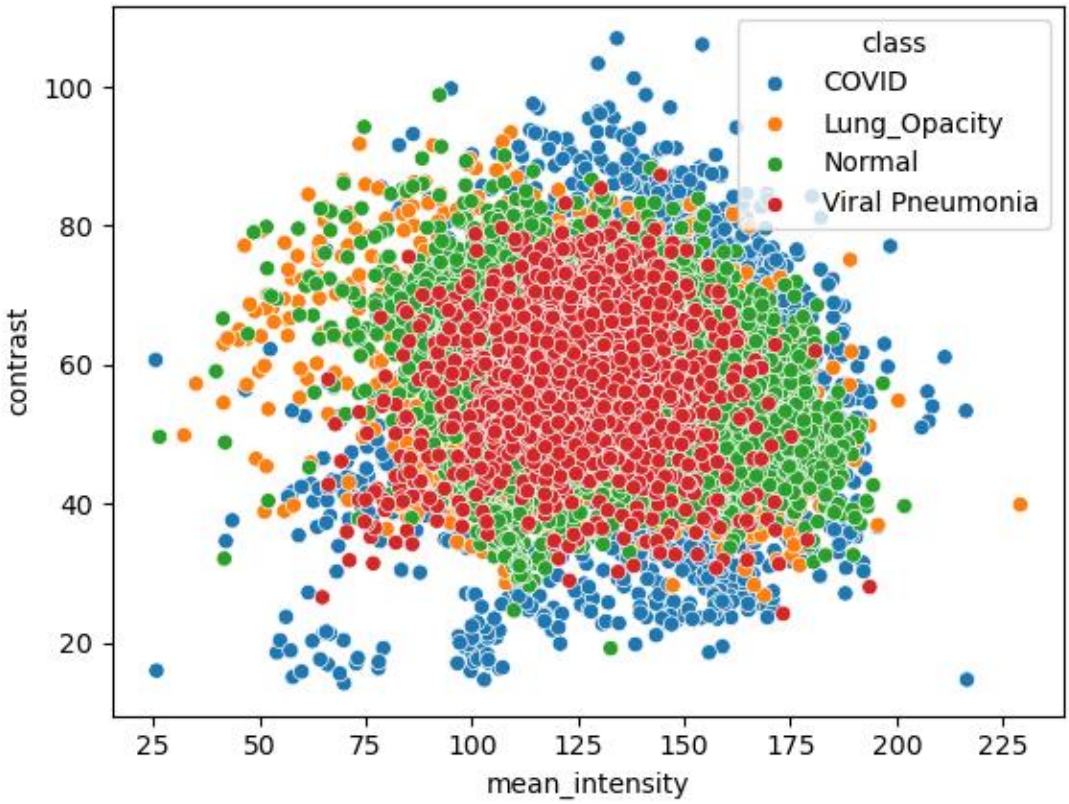


Figure 7 - Relation entre intensité moyenne et contraste selon la classe.

Le fort chevauchement entre les classes confirme que ces statistiques globales ne suffisent pas à discriminer les pathologies.

2.6 Conclusion de l'exploration

L'EDA met en évidence un dataset techniquement exploitable : aucune image corrompue, dimensions uniformes (299 × 299) et modes très majoritairement en niveaux de gris. Elle confirme en revanche un déséquilibre des classes et quelques variations d'intensité/contraste. Le chevauchement des statistiques globales suggère que la discrimination doit surtout reposer sur des motifs visuels locaux, ce qui motive le recours aux CNN et au transfer learning. Les décisions de préprocessing portent donc sur la définition de la cible, le split stratifié, l'harmonisation des canaux, le redimensionnement et le preprocessing des pixels adapté au modèle.

Observation	Impact potentiel	Traitement retenu
Déséquilibre des classes	Biais vers la classe majoritaire	Split stratifié ; suivi Recall/F1 ; OS/DA selon expérience
Modes L/RGB	Entrées non homogènes	Harmonisation adaptée à la famille de modèle
Intensité variable	Instabilité potentielle	Normalisation / preprocessing spécifique
Images atypiques	Outliers visuels	Vérification et conservation/suppression argumentée
Dimensions homogènes	Risque limité lié à la taille	Redimensionnement 224 x 224 pour la modélisation
Aucun fichier corrompu	Pas de nettoyage associé	Aucune action spécifique

Tableau 1 - Synthèse des constats issus de l'exploration et actions associées.

3. Préprocessing

3.1 Définition de la cible binaire

La cible distingue COVID (1) de Non-COVID (0). Les classes Normal, Lung Opacity et Viral Pneumonia sont regroupées dans la classe Non-COVID afin de rester alignés avec la problématique de détection du COVID.

Classe d'origine	Cible
COVID	1
Normal	0
Lung Opacity	0
Viral Pneumonia	0

Tableau 2 - Regroupement des classes pour la classification binaire.

3.2 Séparation train / validation / test

Un split unique et stratifié est utilisé pour toutes les expériences : 64 % entraînement (13 545 images), 16 % validation (3 387 images) et 20 % test (4 233 images). La proportion de COVID est conservée dans chaque sous-ensemble : 17,08 % en entraînement, 17,09 % en validation et 17,08 % en test. Des assertions sur les chemins d'images confirment l'absence de chevauchement entre les trois ensembles. Le jeu de test reste isolé jusqu'à la sélection finale du modèle.

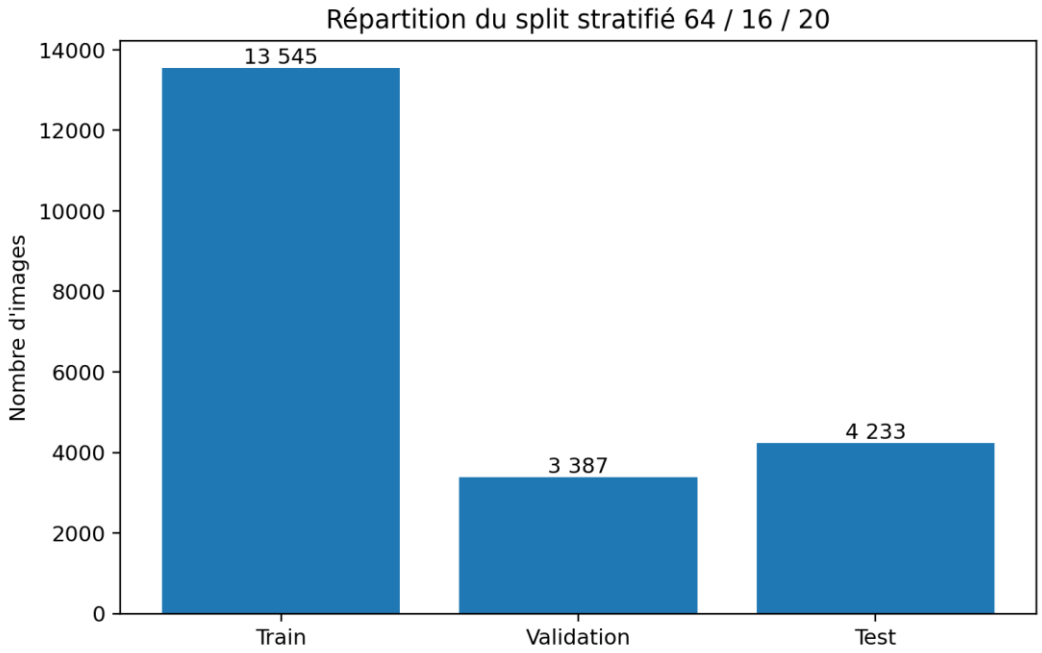


Figure 8 - Répartition des observations entre train, validation et test.

Le split stratifié 64/16/20 conserve la proportion de la classe COVID dans chaque sous-ensemble et isole le test pour l'évaluation finale.

3.3 Préparation des images selon la famille de modèles

Le redimensionnement en 224 x 224 et le split sont communs aux expériences. Le prétraitement des pixels est en revanche adapté à l'architecture utilisée.

Famille	Canaux	Prétraitement	Expériences
CNN scratch	Grayscale (1 canal)	Rescale 1/255	E0, E2, E3
Transfer Learning VGG16	RGB (3 canaux)	VGG16 preprocess_input	E4, E6, E7

Tableau 3 - Prétraitement appliqué selon la famille de modèles.

Les transformations destinées à modifier la diversité ou la distribution des données (data augmentation et oversampling) sont appliquées uniquement au jeu d'entraînement. Validation et test conservent leur distribution d'origine.

3.4 Validation du pipeline de prétraitement

Avant la modélisation, la fonction de preprocessing générique a été contrôlée sur 8 images représentatives sélectionnées à partir de l'EDA : modes L et RGB, cas COVID et Non-COVID, ainsi que des extrêmes d'intensité et de contraste. Les 8 images ont été prétraitées sans erreur. Le contrôle d'une sortie confirme une taille de 224 × 224, un type float32 et des valeurs ramenées dans l'intervalle attendu après normalisation (exemple contrôlé : 0 à 0,8627). Ce contrôle valide la chaîne conversion des canaux → redimensionnement → normalisation pour la branche CNN. Pour VGG16, le même split et le redimensionnement 224 × 224 sont conservés, mais les images sont chargées en RGB et traitées avec preprocess_input, conformément au preprocessing spécifique de cette architecture.

4. Modélisation

4.1 Protocole expérimental

Le protocole compare les CNN entraînés depuis zéro et les modèles VGG16 en transfer learning, dans deux tâches : classification binaire COVID / Non-COVID et classification multiclasses (COVID, Normal, Lung Opacity, Viral Pneumonia). Les expériences partagent le même split stratifié (13 545 entraînement, 3 387 validation, 4 233 test). Le preprocessing dépend de la famille de modèles ; les augmentations et l'oversampling, lorsqu'ils sont utilisés, concernent exclusivement l'entraînement. Le jeu de test reste réservé à l'évaluation finale..

Exp.	Modèle	OS	DA	Responsable	Statut
E0	CNN scratch	Non	Non	R	Terminé — validation
E1	CNN scratch	Oui	Non	K	Non retenu
E2	CNN scratch	Non	Oui	K	Terminé — validation
E3	CNN scratch	Oui	Oui	K	Terminé — validation
E4	VGG16 TL	Non	Non	R	Terminé — validation
E5	VGG16 TL	Oui	Non	R	Non retenu
E6	VGG16 TL	Non	Oui	R	Terminé — validation
E7	VGG16 TL	Oui	Oui	R	Terminé — validation

Tableau 4 — Plan des expériences (colonnes de suivi conservées pour la version de travail).

4.2 E0 - CNN baseline

E0 constitue la baseline : un CNN entraîné depuis zéro, sans oversampling ni data augmentation, sur les images grayscale 224 x 224 normalisées par rescale 1/255. L'architecture comprend trois blocs Conv2D / MaxPooling2D avec 32, 64 puis 128 filtres, suivis d'un Flatten, d'une couche Dense de 128 neurones avec ReLU, d'un Dropout de 0,5 et d'une sortie sigmoïde. Le modèle comporte 11 168 513 paramètres ; l'essentiel se situe dans la couche Dense après Flatten, ce qui constitue un point de vigilance pour le surapprentissage.

L'entraînement utilise Adam (learning rate 0,001), la binary cross-entropy, un batch size de 32 et un budget de 5 epochs. Accuracy, Precision, Recall et AUC sont suivis pendant l'apprentissage. Un EarlyStopping surveille val_loss avec une patience de 2 et restaure les meilleurs poids. Le test n'est pas utilisé.

Métrique	Validation E0
Accuracy	95,3 %
Precision COVID	86,7 %
Recall COVID	85,7 %
F1-score COVID	86,0 %
AUC	98,1 %
Faux négatifs	83
Faux positifs	76

Tableau 5 - Résultats de validation du modèle E0.

Sur les 3 387 images de validation, E0 classe correctement 2 732 Non-COVID et 496 COVID ; il produit 76 faux positifs et 83 faux négatifs. Pour la classe COVID, la précision atteint 86,7 %, le recall 85,7 % et le F1-score environ 0,86 ; l'accuracy globale est de 95,3 % et l'AUC de 0,981. La val_loss passe de 0,2584 à 0,1272 entre les epochs 1 et 5 et le recall de validation de 49,4 % à 85,7 %. Les fluctuations intermédiaires invitent toutefois à comparer les stratégies sur plusieurs métriques plutôt que sur l'accuracy seule. Ces résultats constituent la baseline de validation, et non l'évaluation finale sur test.

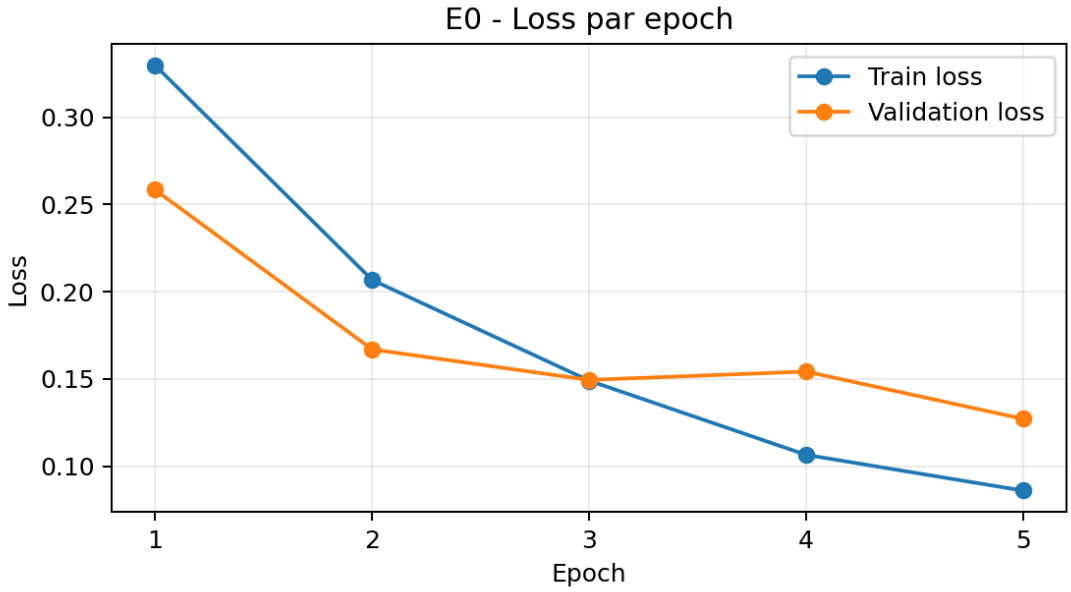


Figure 9 - Évolution de la loss pour E0 (train / validation).

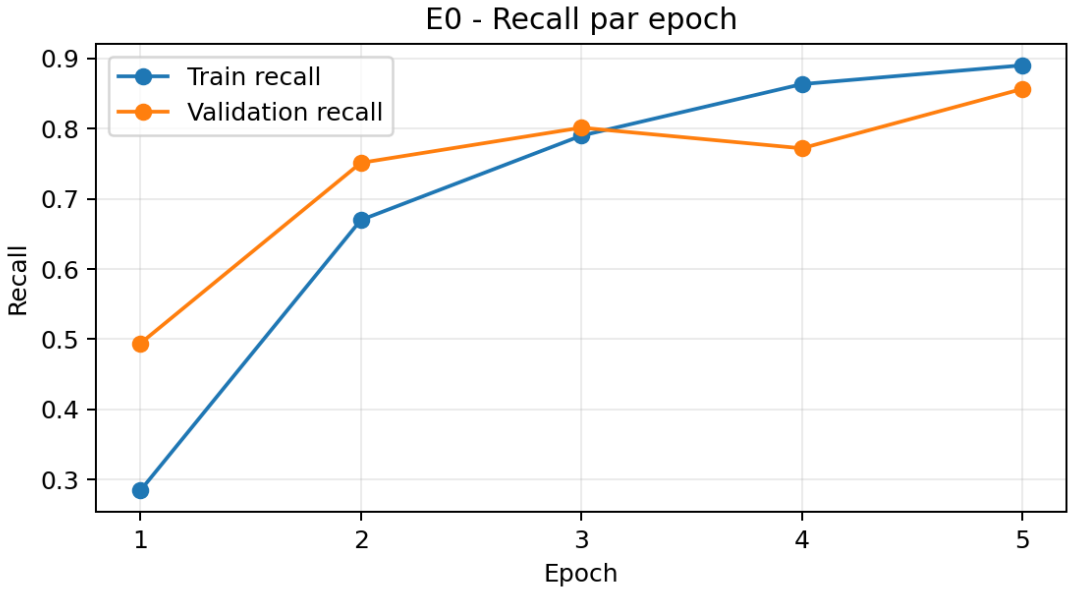


Figure 10 - Évolution du recall pour E0 (train / validation).

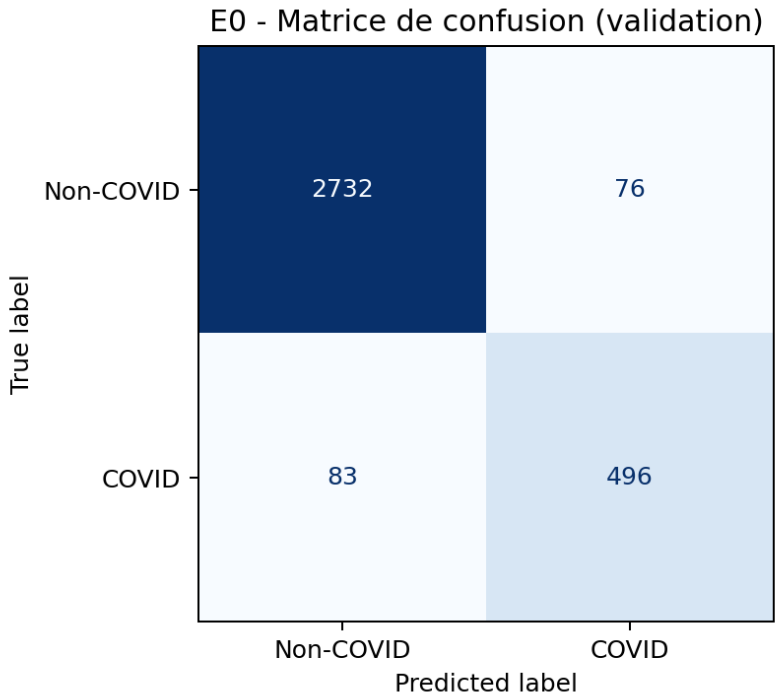


Figure 11 - Matrice de confusion de E0 sur le jeu de validation.

4.3 E4 - Transfer Learning VGG16 baseline

E4 évalue le Transfer Learning sans oversampling ni data augmentation. VGG16 pré-entraîné sur ImageNet est chargé avec include_top=False : son classifieur d'origine est retiré et la base convolutionnelle est gelée afin d'être utilisée comme extracteur de caractéristiques. Le classifieur ajouté comprend un GlobalAveragePooling2D, une couche Dense de 128 neurones avec ReLU, un Dropout de 0,5 et une sortie sigmoïde. Le modèle totalise 14 780 481 paramètres, dont seulement 65 793 sont entraînables ; 14 714 688 paramètres de VGG16 restent gelés.

Les images sont chargées en RGB 224 x 224 et préparées avec preprocess_input de VGG16. Lorsque cela est applicable, le protocole reste aligné sur E0 : Adam (0,001), binary cross-entropy, batch size 32, 5 epochs, EarlyStopping sur val_loss et mêmes métriques. Un ModelCheckpoint sauvegarde le meilleur modèle selon val_loss. Cette différence de preprocessing est nécessaire à VGG16 et ne remet pas en cause l'utilisation du même split de données.

Métrique	Validation E4
Accuracy	96,69 %
Precision COVID	92,1 %
Recall COVID	88,3 %
F1-score COVID	90,0 %
AUC	98,8 %
Faux négatifs	68
Faux positifs	44

Tableau 6 - Résultats de validation du modèle E4.

Sur validation, E4 classe correctement 2 764 Non-COVID et 511 COVID ; il produit 44 faux positifs et 68 faux négatifs. Pour la classe COVID, la précision atteint environ 92,1 %, le recall 88,3 % et le F1-score 0,90 ; l'accuracy est de 96,69 % et l'AUC de 0,988. La val_loss diminue globalement de 0,1506 à 0,0942 sur les cinq epochs et le recall de validation progresse de 71,5 % à 88,3 %. Le meilleur checkpoint correspond à l'epoch 5 selon val_loss.

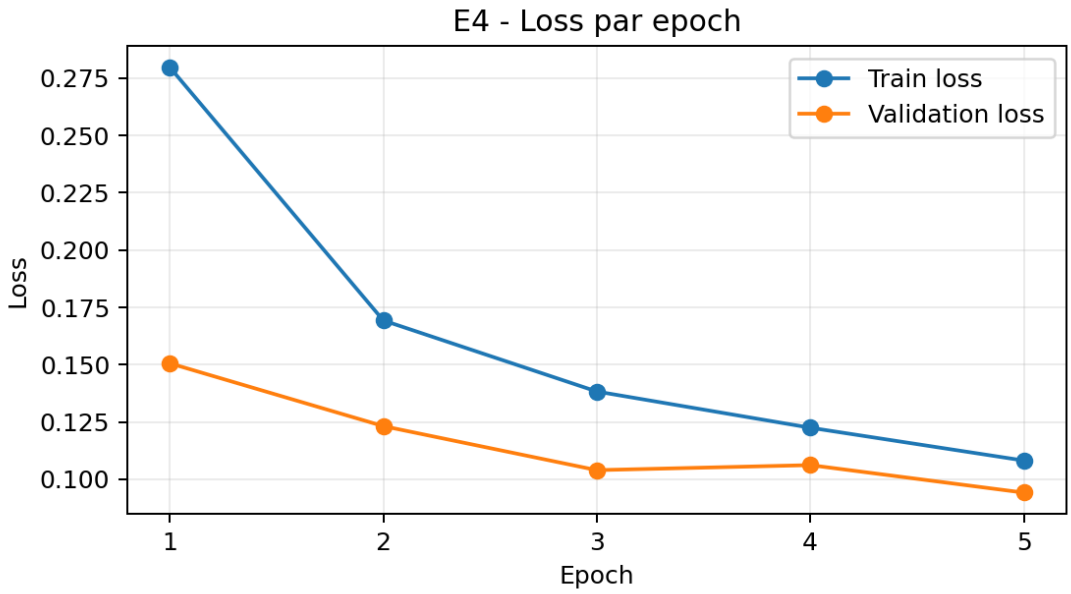


Figure 12 - Évolution de la loss pour E4 (train / validation).

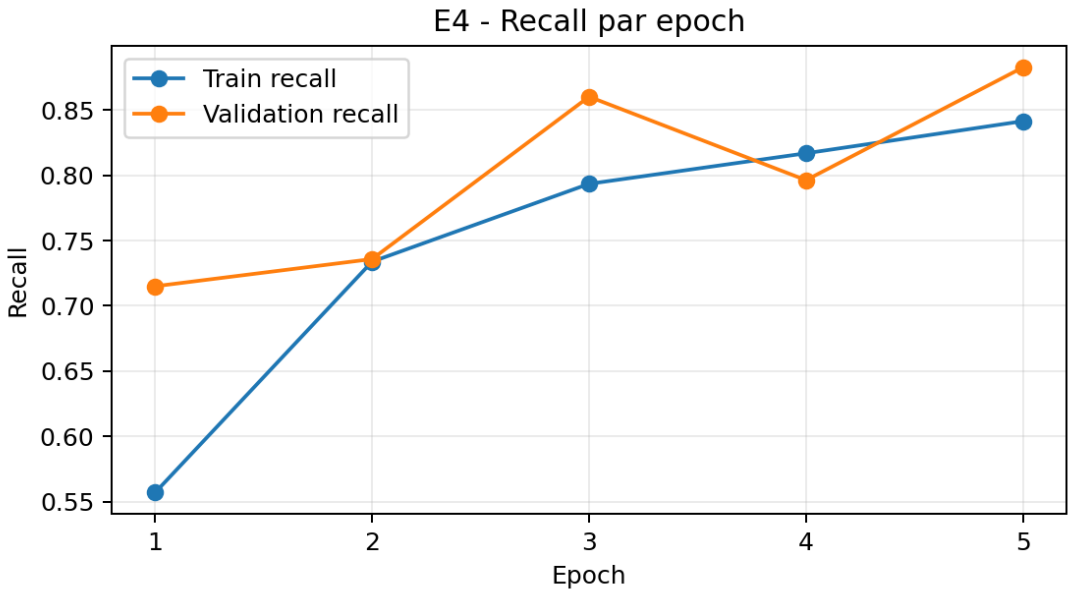


Figure 13 - Évolution du recall pour E4 (train / validation).

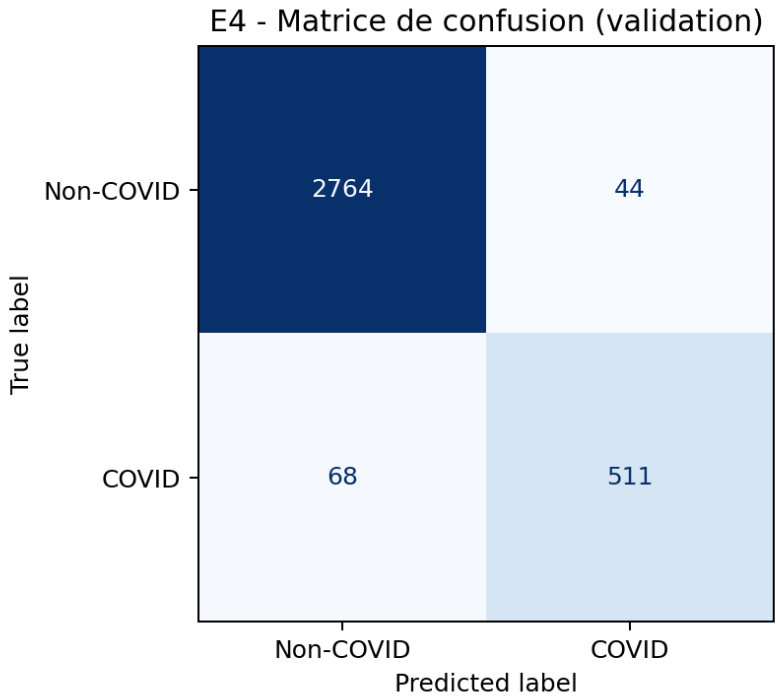


Figure 14 - Matrice de confusion de E4 sur le jeu de validation.

4.4 E2 — CNN avec data augmentation (sans oversampling)

E2 conserve le CNN de référence et applique la data augmentation uniquement à l'entraînement. Sur 3 387 images de validation : accuracy 93,68 % ; précision COVID 88,91 % ; recall COVID 72,02 % ; F1 COVID 79,58 %. Parmi les 579 images COVID, 417 sont détectées et 162 manquées ; 52 images Non-COVID sont faussement signalées COVID. Cette configuration privilégie la précision au détriment du rappel, critère essentiel pour la détection COVID.

Sur les 579 cas COVID de validation, E2 en détecte 417 et en manque 162. La matrice de confusion montre également 52 faux positifs. Le rappel de 72,02 % reste inférieur à celui d'E0, malgré une précision COVID de 88,91 %. La data augmentation seule ne constitue donc pas une amélioration sur le critère de détection des cas COVID dans cette expérience.

Métrique	Validation E2
Accuracy globale	93,68 %
Précision COVID	88,91 %
Rappel COVID	72,02 %
F1 COVID	79,58 %
Faux négatifs COVID	162
Faux positifs COVID	52

Tableau — Résultats de validation du modèle E2.

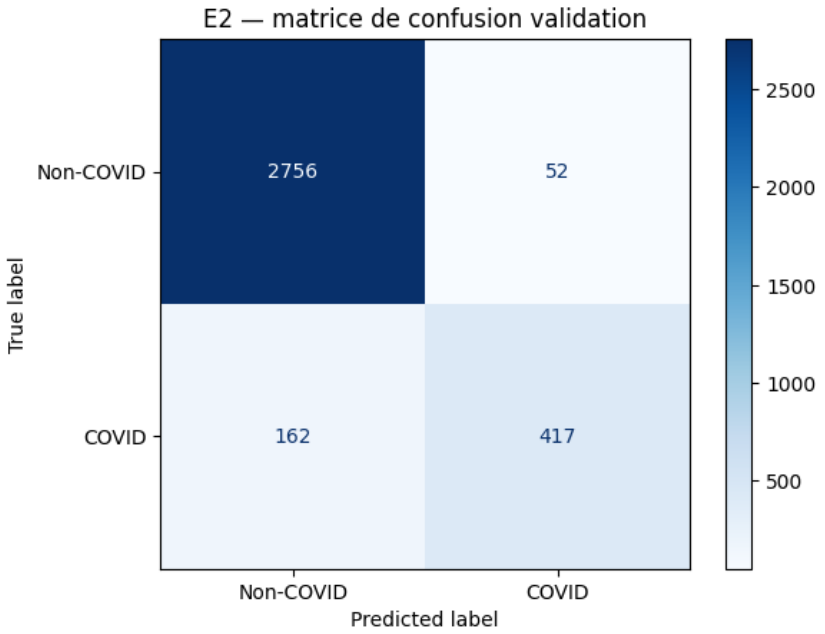


Figure — E2 : Matrice de confusion sur validation (issue du notebook).

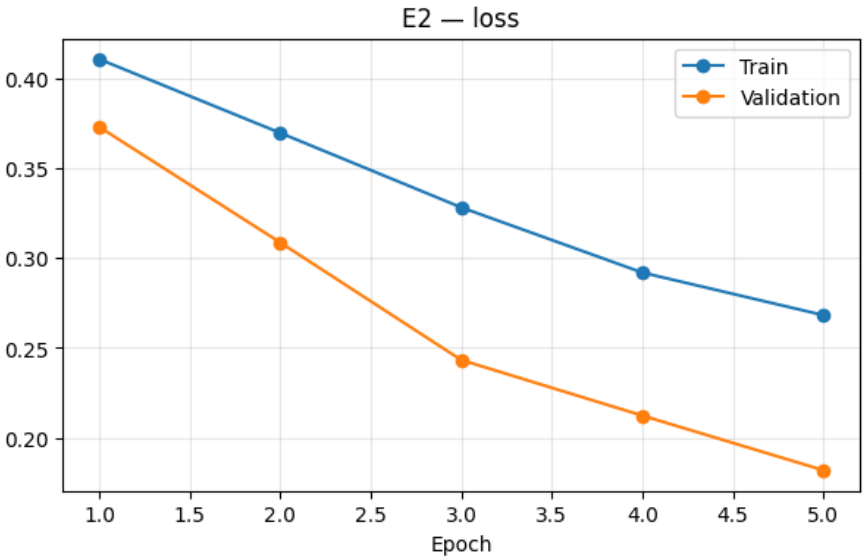


Figure — E2 : Évolution de la loss (train / validation) (issue du notebook).

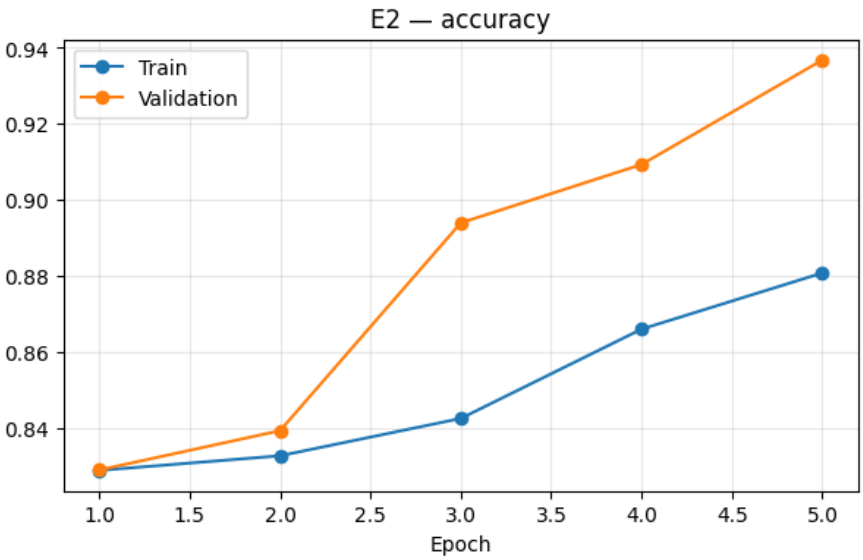


Figure — E2 : Évolution de l'accuracy (train / validation) (issue du notebook).

4.5 E3 — CNN avec oversampling et data augmentation

E3 reprend l'architecture de E0, applique l'oversampling exclusivement sur l'entraînement (22 462 observations, soit 11 231 par classe), puis la data augmentation sur le train. Sur validation, il atteint 94,30 % de recall COVID, 87,01 % de F1 COVID et 80,77 % de précision COVID. Le gain de rappel s'accompagne donc d'un nombre accru de faux positifs par rapport à E4.

Sur les 579 cas COVID de validation, E3 en détecte 546 et en manque 33, avec 130 faux positifs. Par rapport à E2, l'association oversampling et data augmentation améliore nettement le rappel COVID (72,02 % à 94,30 %) et le F1 COVID (79,58 % à 87,01 %), au prix d'une baisse de précision (88,91 % à 80,77 %). Ces résultats concernent le CNN E3 initial, et non sa variante optimisée.

Métrique	Validation E3
Accuracy globale	95,19 %
Précision COVID	80,77 %
Rappel COVID	94,30 %
F1 COVID	87,01 %
Faux négatifs COVID	33
Faux positifs COVID	130

Tableau — Résultats de validation du modèle E3.

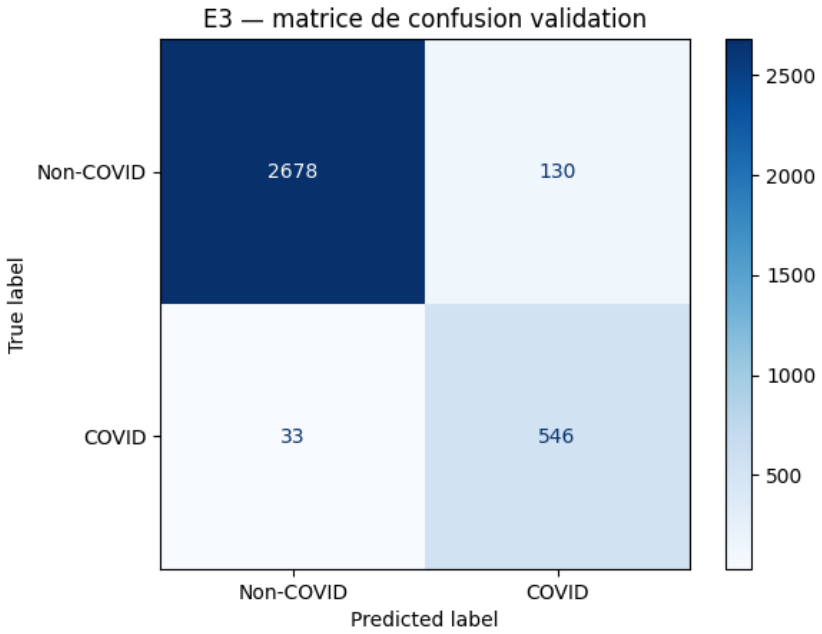


Figure — E3 : Matrice de confusion sur validation (issue du notebook).

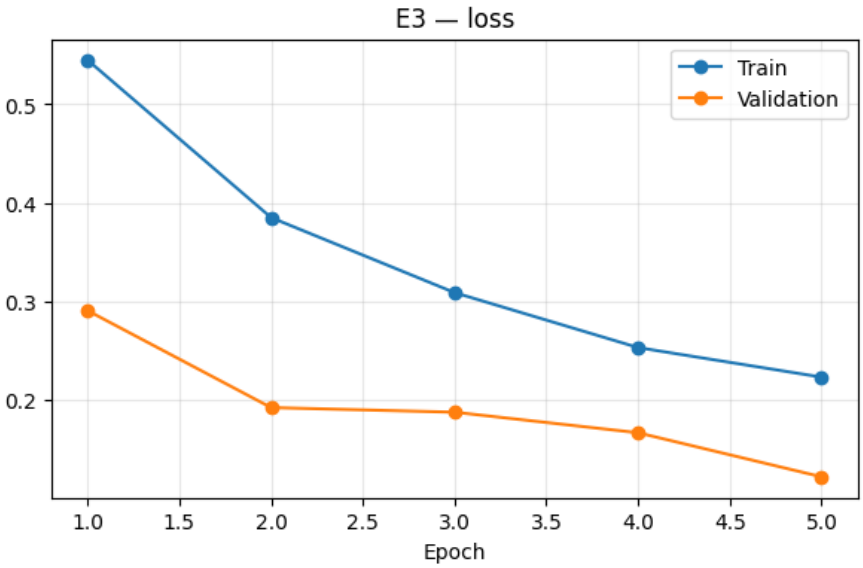


Figure — E3 : Évolution de la loss (train / validation) (issue du notebook).

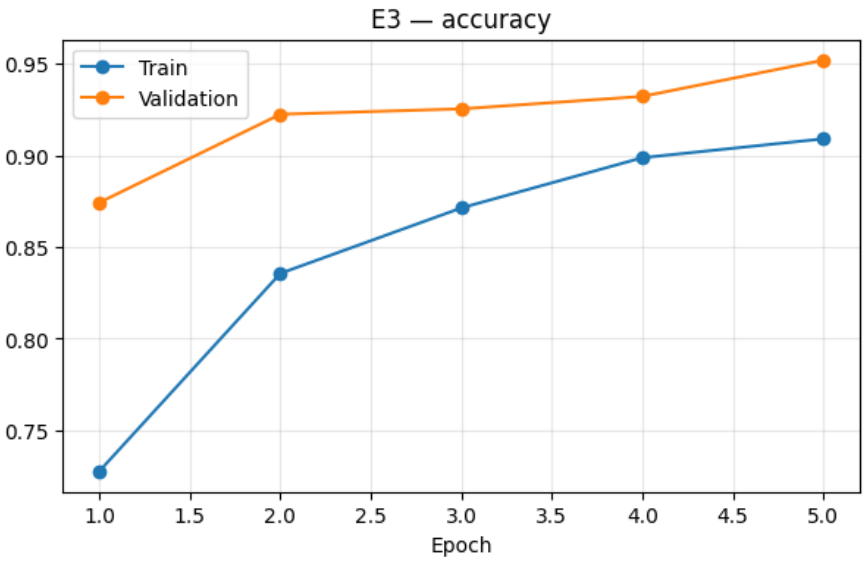


Figure — E3 : Évolution de l'accuracy (train / validation) (issue du notebook).

Les matrices de confusion et les checkpoints sont documentés dans les sections consacrées aux expériences et à leur évaluation finale.

4.6 E6 - VGG16 avec data augmentation

E6 reprend l'architecture de E4 : VGG16 pré-entraîné sur ImageNet, base convolutionnelle gelée, GlobalAveragePooling2D, Dense 128 avec ReLU, Dropout 0,5 et sortie sigmoïde. Les images sont traitées en RGB 224 × 224 avec preprocess_input. La seule modification par rapport à E4 est l'ajout d'une data augmentation sur le train : rotation ±10°, translations horizontale et verticale de 10 % et zoom de 10 %. Aucun retournement horizontal n'est appliqué. La validation conserve uniquement le preprocessing VGG16.

L'entraînement utilise Adam (learning rate 0,001), la binary cross-entropy, un batch size de 32 et un maximum de 5 epochs. EarlyStopping surveille val_loss avec une patience de 2 et restaure les meilleurs poids ; ModelCheckpoint sauvegarde également le meilleur modèle. Le meilleur val_loss est obtenu à l'epoch 4 (0,1498). À l'epoch 5, la loss de validation remonte à 0,1824 alors que les métriques d'entraînement continuent globalement de progresser, ce qui constitue un signal de divergence train/validation.

Métrique	**Validation E6**
Accuracy	94,63 %
Precision COVID	92,51 %
Recall COVID	74,61 %
F1-score COVID	82,60 %
AUC (epoch 4)	97,37 %
Faux négatifs	147
Faux positifs	35

Tableau 7 - Résultats de validation du modèle E6.

Avec 432 vrais positifs sur 579 cas COVID, E6 conserve une précision élevée mais manque 147 cas COVID. Par rapport à E4, la data augmentation seule réduit les faux positifs (44 → 35) mais augmente fortement les faux négatifs (68 → 147). Le Recall COVID passe ainsi de 88,3 % à 74,6 % et le F1-score d'environ 90,0 % à 82,6 %. Dans le cadre retenu, où Recall et F1-score sont les deux métriques principales, E6 n'améliore donc pas E4. Ce résultat motive la poursuite de l'expérimentation avec E7, qui combinera data augmentation et oversampling.

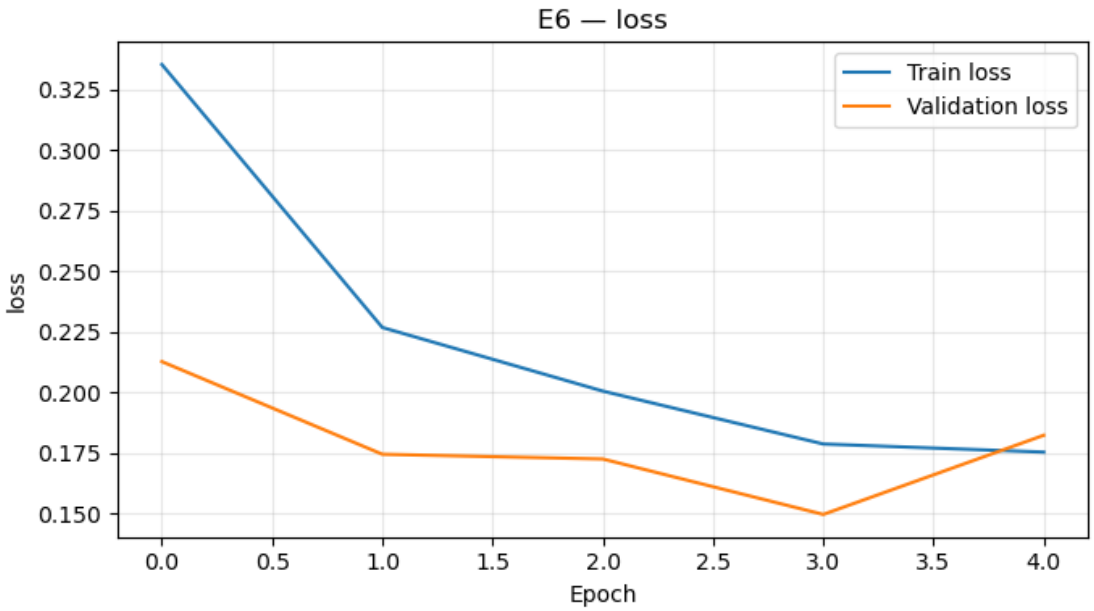


Figure 13 - Évolution de la loss pour E6 (train / validation).

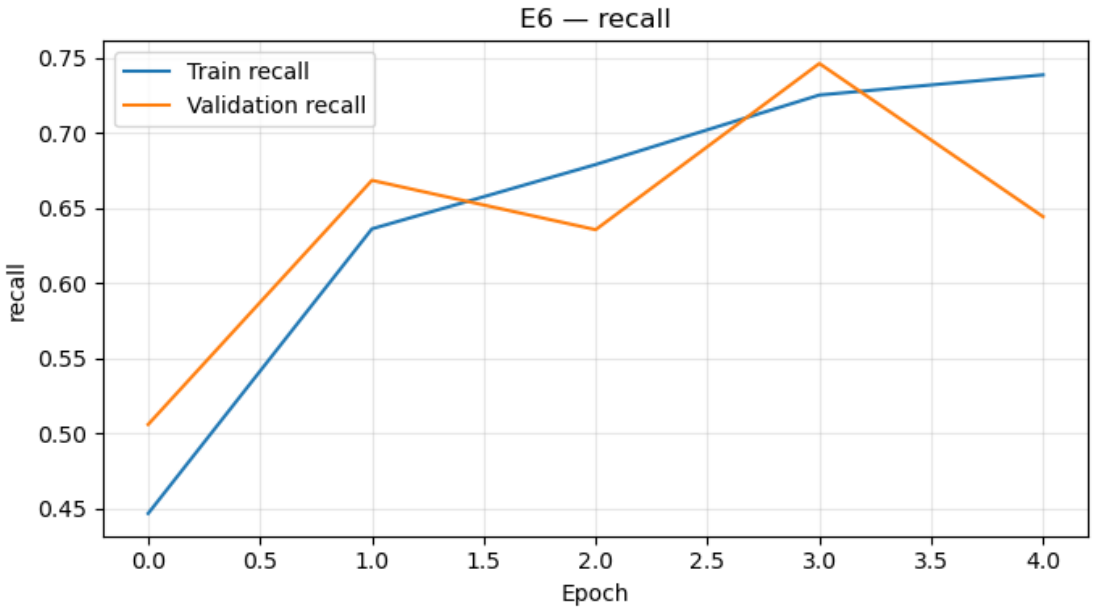


Figure 14 - Évolution du recall pour E6 (train / validation).

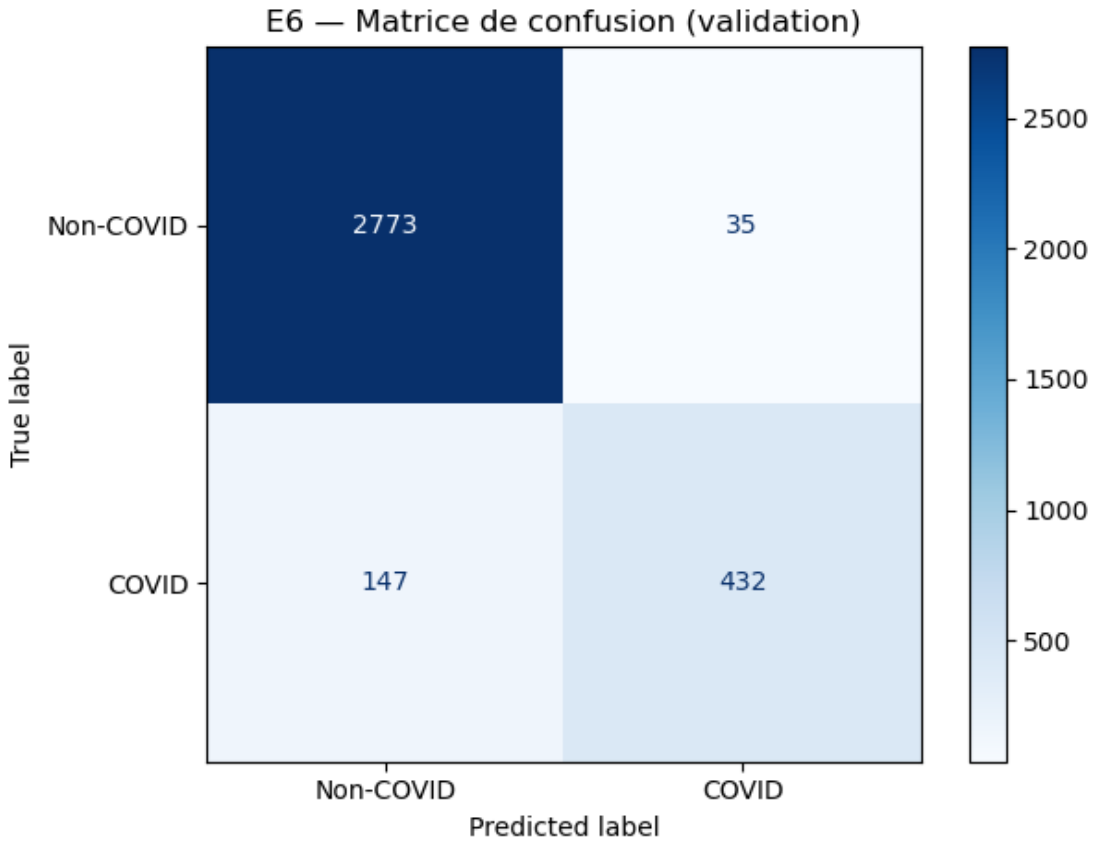


Figure 15 - Matrice de confusion de E6 sur le jeu de validation.

4.7 E7 - VGG16 avec oversampling et data augmentation

E7 reprend la configuration VGG16 de E6, avec data augmentation légère et RandomOverSampler(random_state=42) sur le train uniquement, équilibrant COVID et Non-COVID à 50/50. Validation et test restent inchangés. Les résultats ci-dessous concernent exclusivement la validation, avec un seuil de 0,5.

Résultats E7 : accuracy 95,90 % ; precision COVID 91,98 % ; recall COVID 83,25 % ; F1 COVID 87,40 %. Matrice de confusion : TN 2766, FP 42, FN 97, TP 482. Meilleur val_loss à l'epoch 5.

Métrique	Validation E7
Accuracy globale	95,90 %
Précision COVID	91,98 %
Rappel COVID	83,25 %
F1 COVID	87,40 %
Faux négatifs COVID	97
Faux positifs COVID	42

Tableau — Résultats de validation du modèle E7.

Comparé à E6, E7 améliore le recall COVID (74,61 % → 83,25 %) et le F1 COVID (82,60 % → 87,40 %), mais reste inférieur à E4 sur ces deux critères. L'oversampling est donc bénéfique par rapport à E6 dans cette configuration, sans dépasser la baseline TL E4.

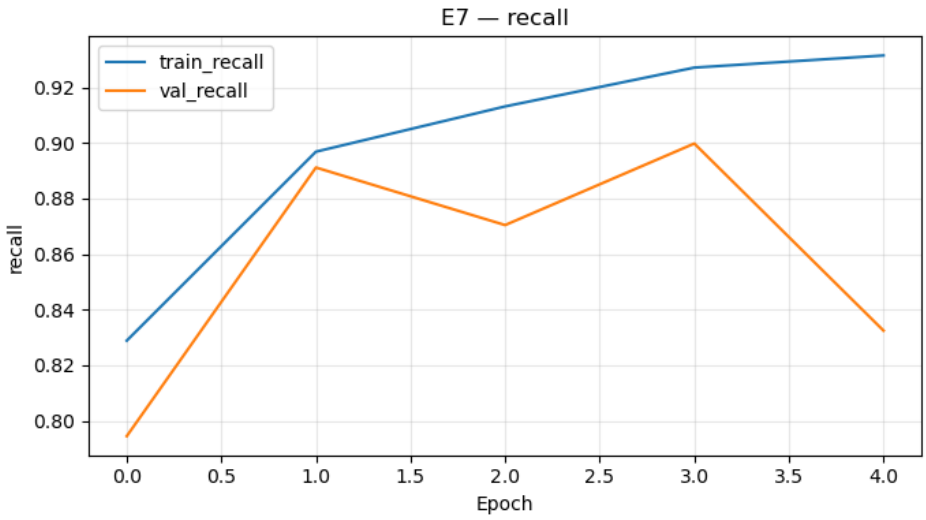


Figure E7 — Sortie graphique de validation / entraînement (notebook E7).

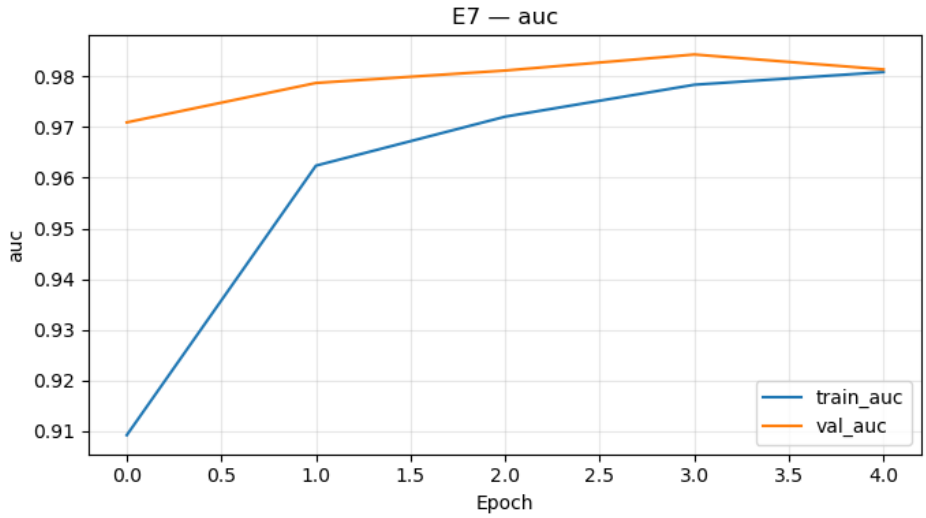


Figure E7 — Sortie graphique de validation / entraînement (notebook E7).

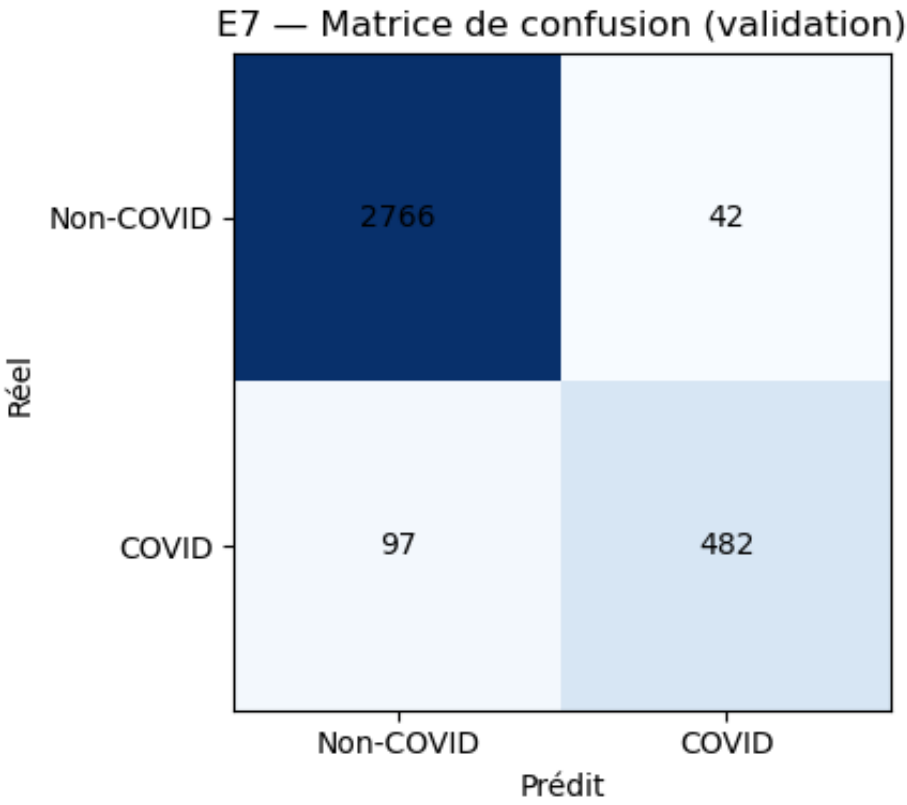


Figure E7 — Sortie graphique de validation / entraînement (notebook E7).

5. Résultats et comparaison des expériences binaires

5.1 E0 et E4 — apport du transfer learning

Sur le même jeu de validation, E4 améliore l'ensemble des métriques suivies par rapport à E0 : accuracy 95,3 % -> 96,7 %, précision COVID 86,7 % -> 92,1 %, recall COVID 85,7 % -> 88,3 %, F1-score COVID 0,86 -> 0,90 et AUC 0,981 -> 0,988. Surtout, les faux positifs diminuent de 76 à 44 (-32, soit environ -42 %) et les faux négatifs de 83 à 68 (-15, soit environ -18 %). Ces résultats montrent qu'en validation, les caractéristiques visuelles pré-entraînées de VGG16 apportent un gain par rapport au CNN scratch, y compris sur la détection de la classe minoritaire COVID.

La comparaison repose sur la même cible, exactement le même split et la même taille d'entrée. Le preprocessing est toutefois spécifique à l'architecture : grayscale + rescale 1/255 pour E0, RGB + preprocess_input pour E4. Il faut donc interpréter E0 -> E4 comme une comparaison de deux stratégies de modélisation complètes, et non comme l'effet isolé d'un unique composant.

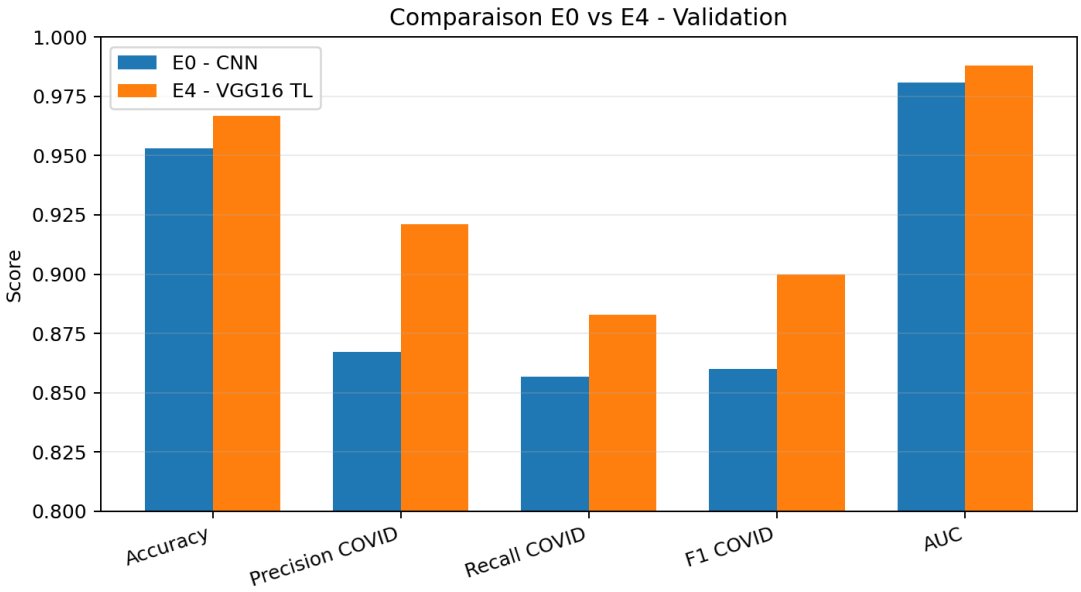


Figure 15 - Comparaison des métriques de validation E0 et E4.

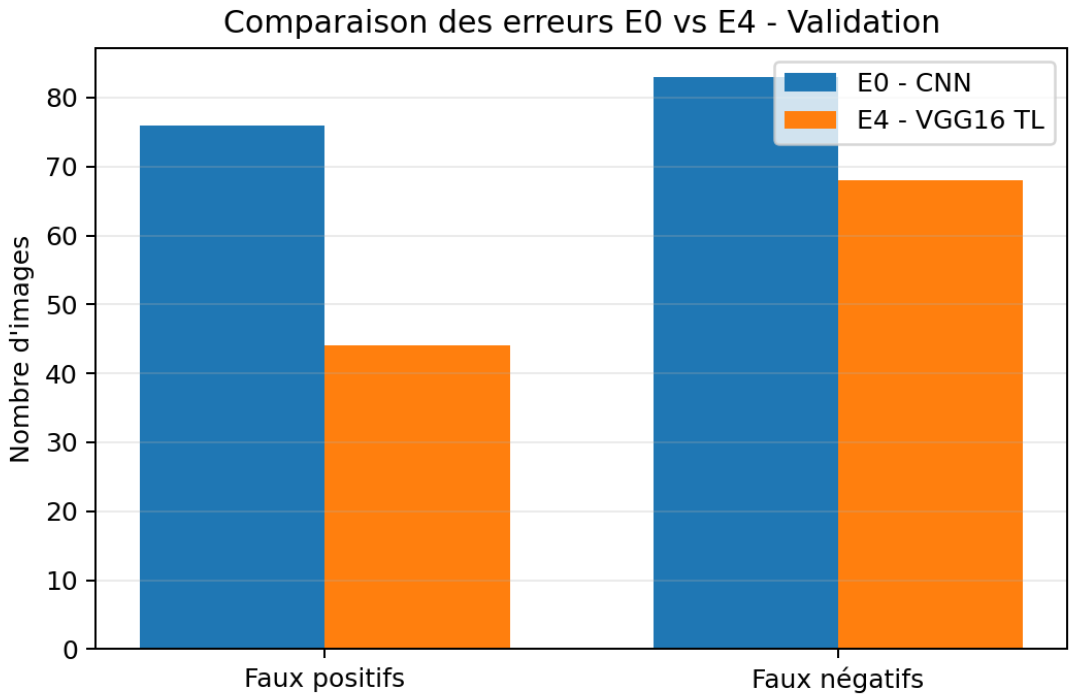


Figure 16 - Comparaison des faux positifs et faux négatifs E0 et E4.

5.2 Comparaison des six expériences binaires retenues

Sur les six expériences binaires E0, E2, E3, E4, E6 et E7, E3 présente le recall COVID maximal (94,30 %) ; E4 présente le meilleur F1 COVID (90,1 %). Le premier privilégie la sensibilité au COVID, le second offre un meilleur compromis précision/rappel. Ces constats portent exclusivement sur les modèles binaires et le jeu de validation.

E2 (CNN + DA) obtient un recall COVID de 72,02 % et un F1 de 79,58 %, alors qu'E3 (CNN + OS + DA) atteint 94,30 % et 87,01 %. Pour les VGG16 binaires, E4 reste devant E6 et E7 sur le recall et le F1 COVID. La comparaison avec les modèles multiclasses est réservée à la section 7.

Exp.	Modèle	OS	DA	Préc. COVID	Recall COVID	F1 COVID
E0	CNN scratch	Non	Non	0,867	0,857	0,86
E1	CNN scratch	Oui	Non	-	-	-

E2	CNN scratch	Non	Oui	88,91 %	72,02 %	79,58 %
E3	CNN scratch	Oui	Oui	80,77 %	94,30 %	87,01 %
E4	VGG16 TL	Non	Non	0,921	0,883	0,90
E5	VGG16 TL	Oui	Non	-	-	-
E6	VGG16 TL	Non	Oui	0,925	0,746	0,826
E7	VGG16 TL	Oui	Oui	0,9198	0,8325	0,8740

La comparaison binaire porte sur les six configurations retenues ; E1 et E5 (oversampling seul) n'ont pas été retenues dans le protocole final.

Tableau 7 — Résultats des expériences binaires sur validation.

L'analyse des CNN binaires E0, E2 et E3 a motivé la transposition des deux stratégies d'augmentation au problème à quatre classes : M2 (CNN + DA, comme E2) et M3 (CNN + OS + DA, comme E3). En parallèle, M4 et M7 reprennent les configurations VGG16 sans puis avec OS + DA.

La classe Non-COVID regroupe trois catégories distinctes (Normal, Lung Opacity et Viral Pneumonia), dont la variabilité justifie d'étudier également une classification à quatre classes. Cette seconde tâche utilise une sortie softmax, un entraînement et une évaluation spécifiques. Elle permet de mesurer la capacité des modèles à distinguer les pathologies au-delà de la seule détection COVID.

6. Résultats et comparaison des expériences multiclasses

6.1 Résultats des quatre expériences : M2, M3, M4 et M7

Les quatre modèles sont évalués sur les mêmes 3 387 images de validation. Leurs scores COVID et leurs moyennes macro sont comparés ci-dessous.

M4 — VGG16 Transfer Learning, sans oversampling ni data augmentation

Métrique	Validation
Accuracy	88,31 %
Précision COVID	83,71 %
Rappel COVID	89,64 %
F1 COVID	86,57 %
Rappel macro	89,56 %
F1 macro	89,29 %

Le modèle M4 a été évalué sur les 3 387 images du jeu de validation commun, sans utiliser le jeu de test. Les résultats ci-dessous correspondent à la dernière évaluation après réentraînement. Les classes sont COVID, Lung_Opacity, Normal et Viral Pneumonia.

Les métriques de validation sont synthétisées dans le tableau ci-dessus.

Le recall COVID élevé signifie que le modèle identifie environ neuf radiographies COVID sur dix en validation. La précision COVID plus faible (83,71 %) indique cependant qu'une partie des images prédites COVID appartient aux autres classes. Le F1 COVID (86,57 %) synthétise ce compromis. Ces observations ne permettent pas, à elles seules, de conclure à une performance clinique ni de choisir définitivement le modèle sans comparaison avec les autres expériences.

Résultats par classe : COVID — recall 89,64 %, F1 86,57 % ; Lung Opacity — recall 83,01 %, F1 84,83 % ; Normal — recall 90,04 %, F1 89,99 % ; Viral Pneumonia — recall 95,54 %, F1 95,75 %. La classe Lung Opacity est la moins bien reconnue selon ces deux métriques ; la classe Viral Pneumonia obtient les meilleurs scores, mais avec un support plus faible (224 images).

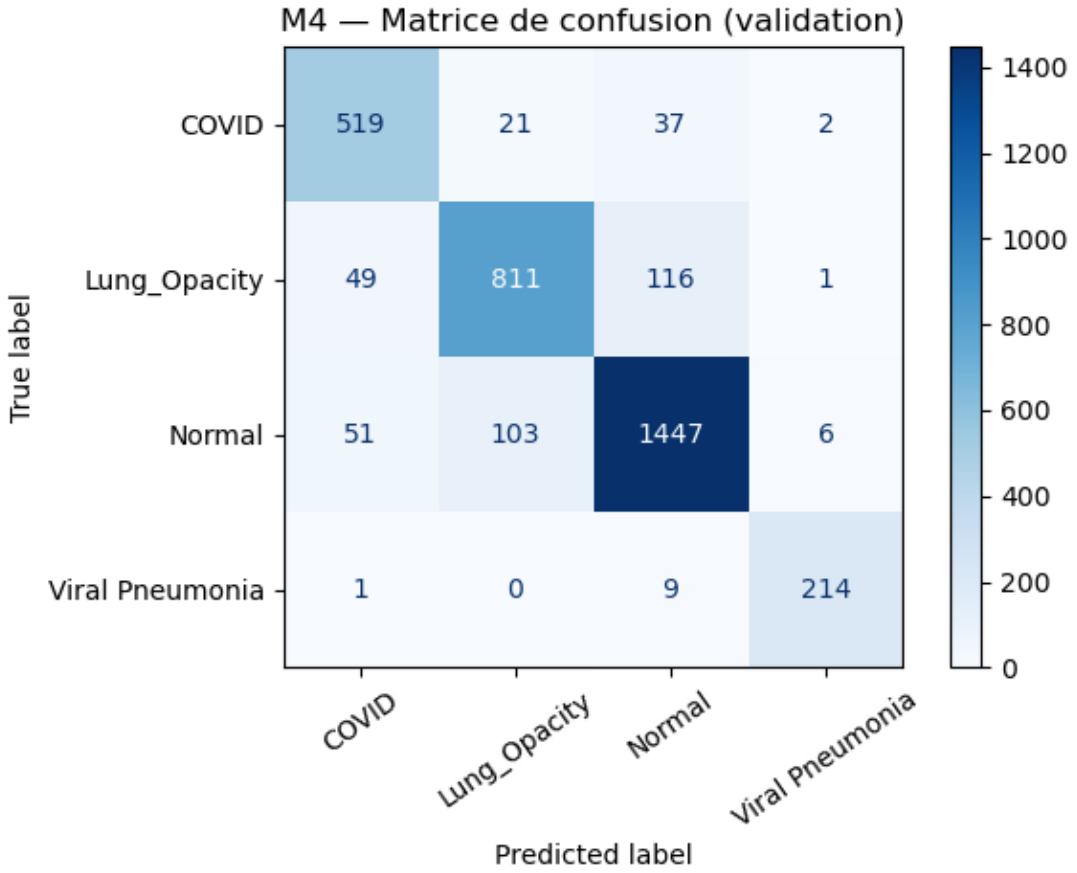


Figure — M4 : matrice de confusion sur validation.

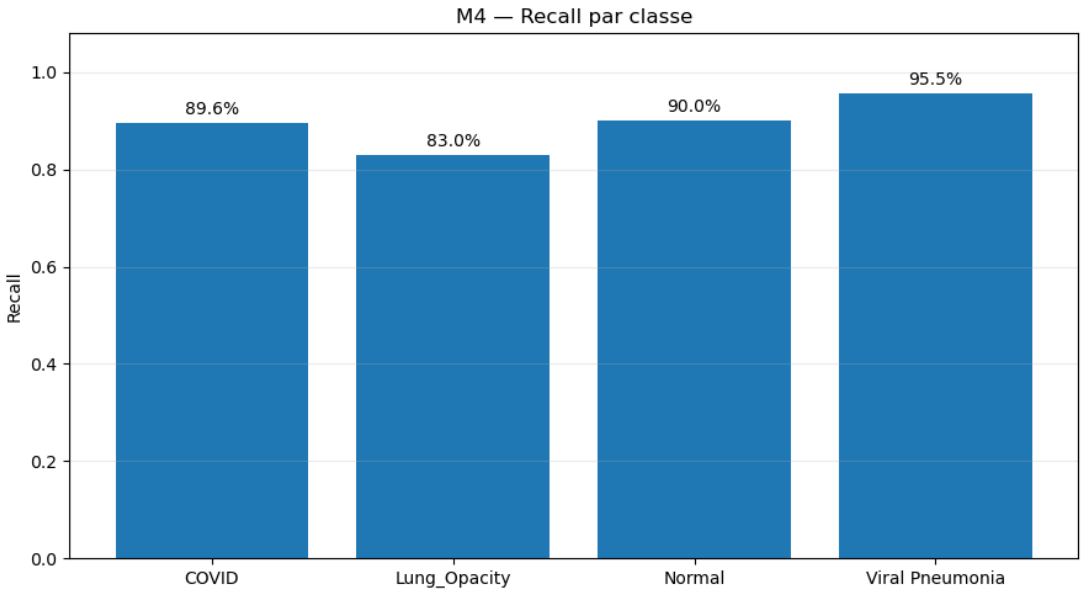


Figure — M4 : recall par classe sur validation.

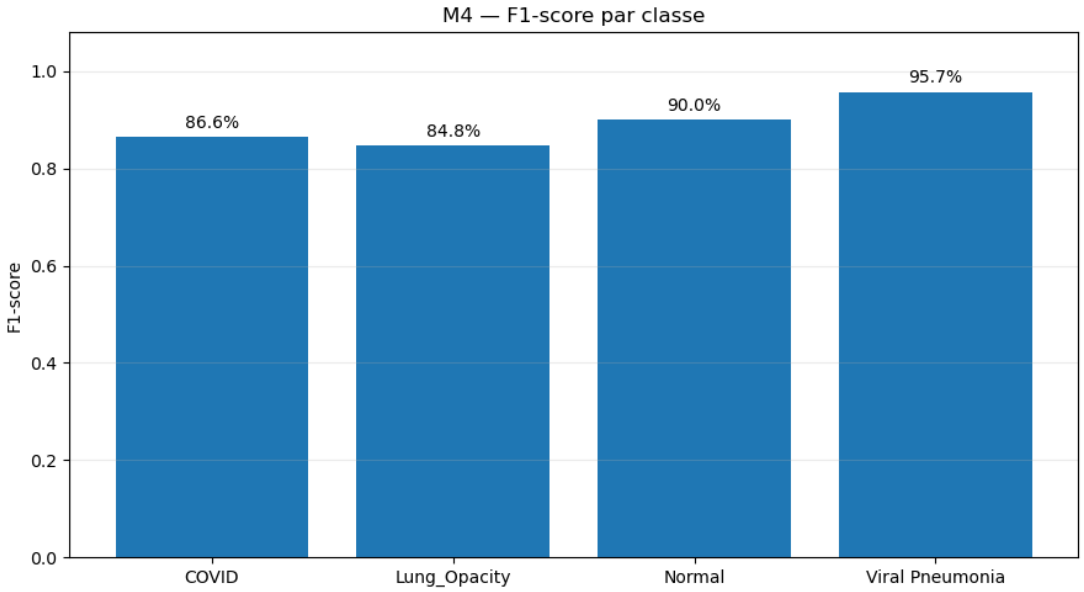
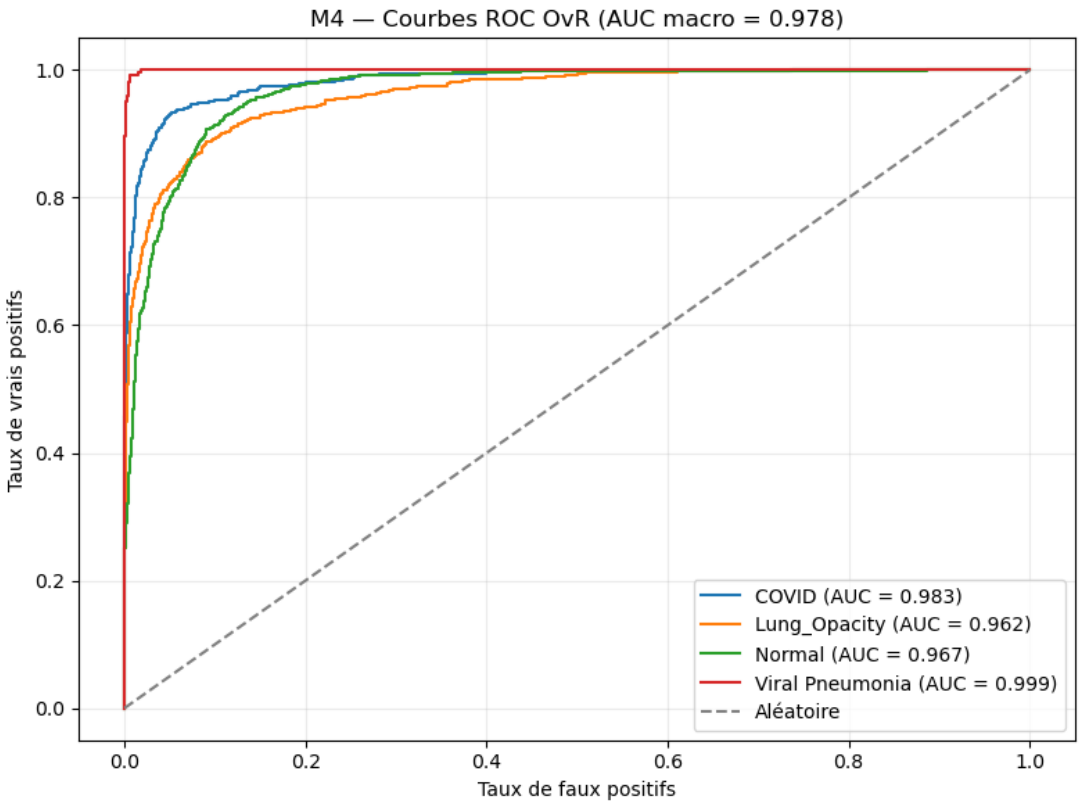


Figure — M4 : F1-score par classe sur validation.



La comparaison entre tâches binaire et multiclasses sur les seules métriques COVID est présentée dans la section 7 ; les métriques macro restent réservées aux quatre modèles multiclasses.

M7 — VGG16 Transfer Learning avec oversampling et data augmentation

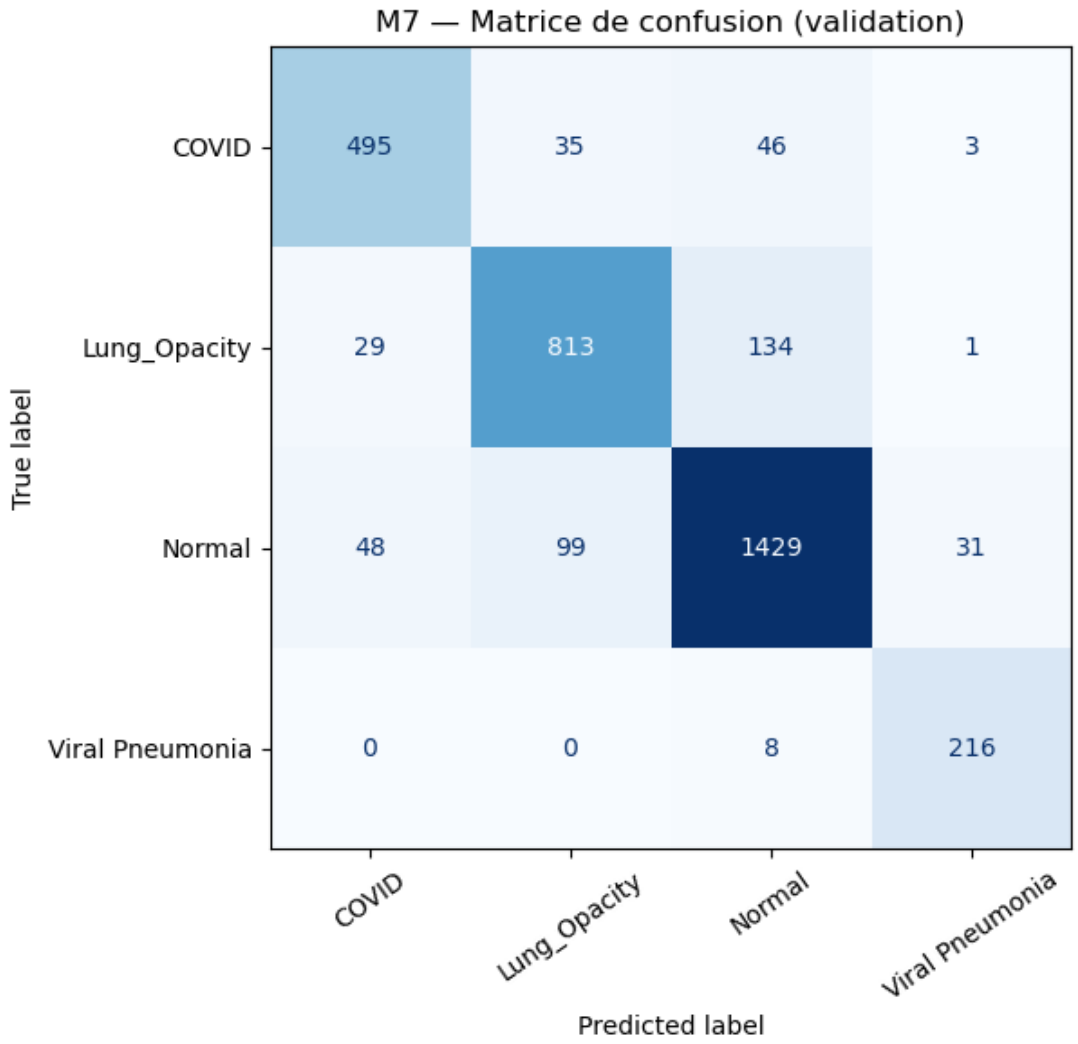
Métrique	Validation
Accuracy	87,19 %
Précision COVID	86,54 %
Rappel COVID	85,49 %
F1 COVID	86,01 %

Rappel macro	88,51 %
F1 macro	87,53 %

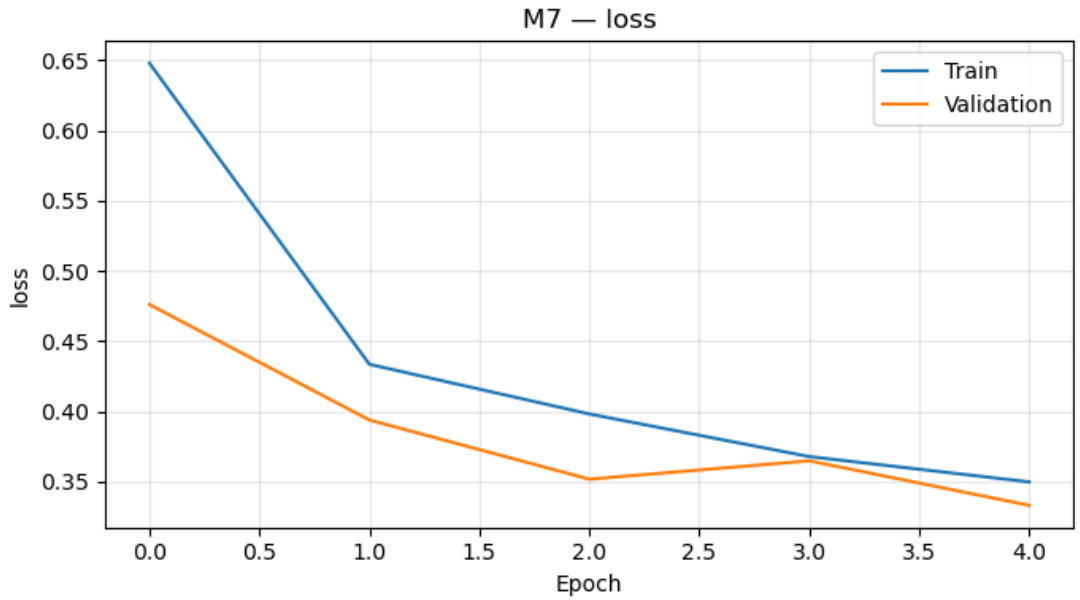
M7 associe VGG16, oversampling et data augmentation sur le jeu d'entraînement. L'évaluation porte sur les 3 387 images de validation, dont 579 COVID. Les résultats chiffrés sont présentés dans le tableau.

Par rapport à M4 (recall COVID 89,64 %, F1 COVID 86,57 %, F1 macro 89,29 %), M7 ne présente pas d'amélioration sur ces critères lors de cette exécution. La data augmentation et l'oversampling combinés ne garantissent donc pas un gain sur cette architecture ; les variations de précision, de distribution et d'entraînement doivent être discutées sans extrapolation.

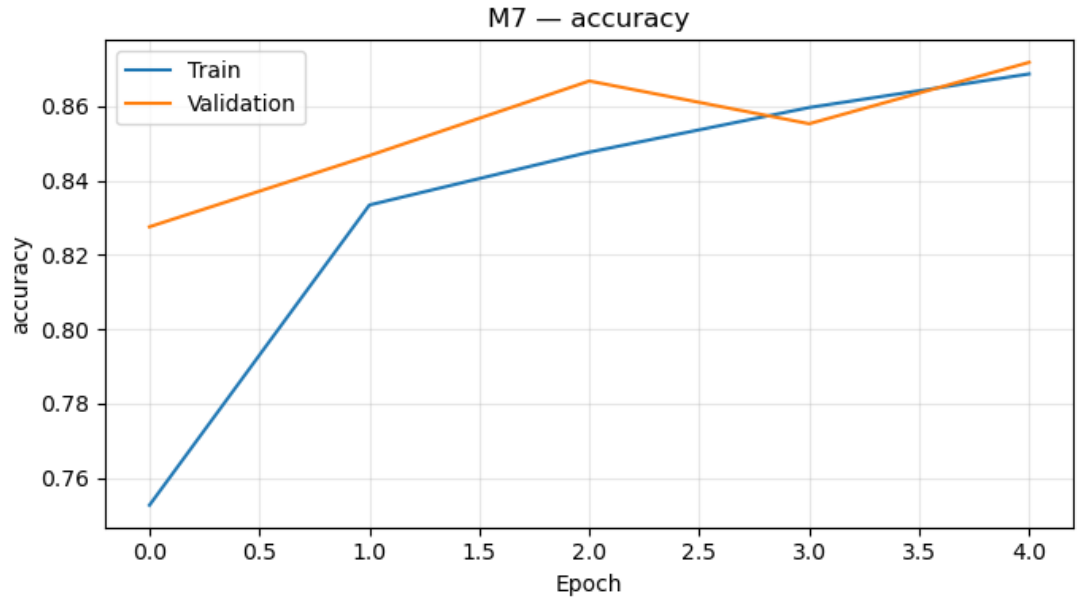
M7 — Matrice de confusion sur validation



M7 — Courbes de loss (train et validation)



M7 — Courbes d'accuracy (train et validation)



M2 — CNN multiclasses avec data augmentation

Métrique	Validation
Accuracy	81,43 %
Précision COVID	77,44 %
Rappel COVID	82,38 %
F1 COVID	79,83 %
Rappel macro	77,30 %
F1 macro	80,03 %

M2 applique la data augmentation à l'entraînement d'un CNN multiclasses, sur le split commun. Son rappel COVID (82,38 %) reste inférieur à celui de M3, et le rappel Viral Pneumonia (66,52 %) pénalise la moyenne macro. Les résultats illustrent les limites de cette configuration sans oversampling.

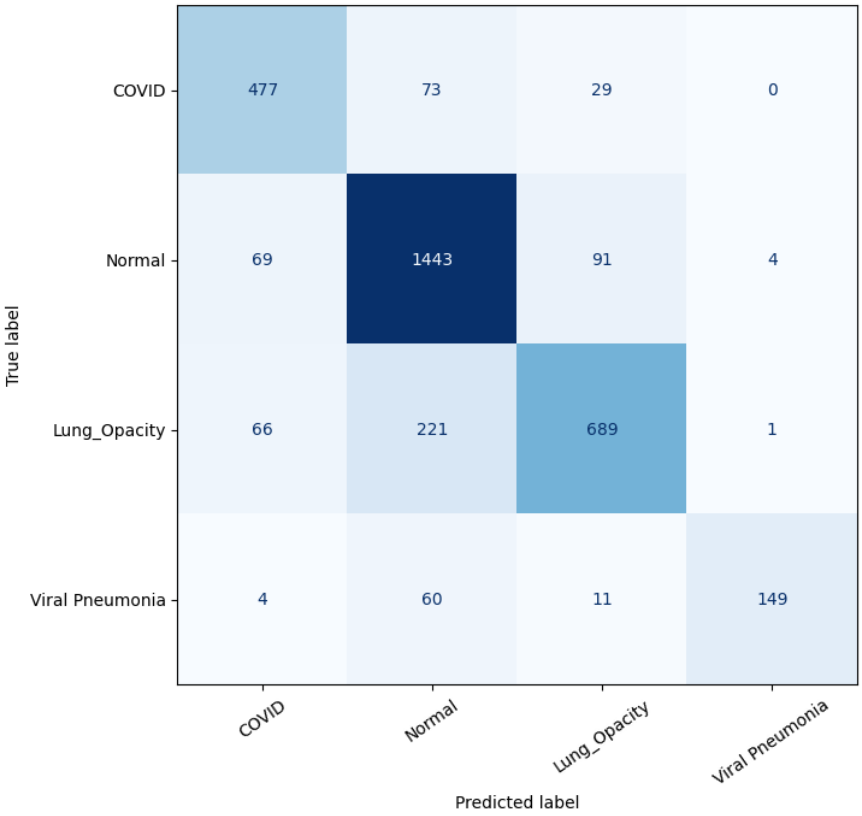


Figure — M2 : Matrice de confusion sur validation (issue du notebook).

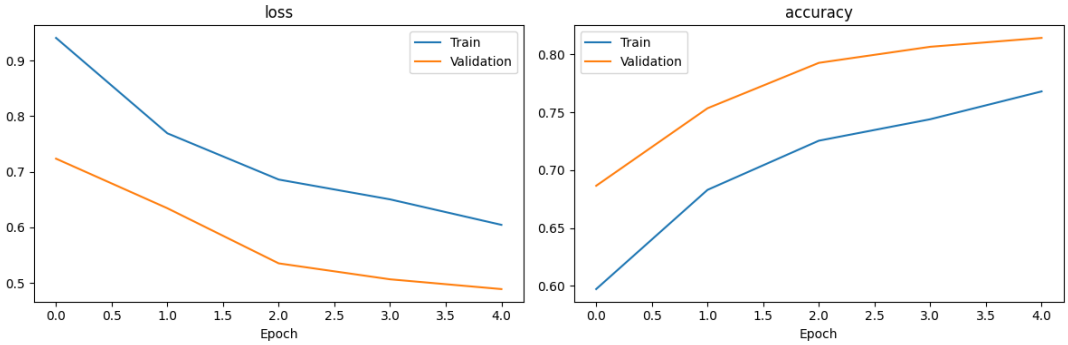


Figure — M2 : Courbes d'entraînement : loss et accuracy (issue du notebook).

M3 — CNN multiclasses avec oversampling et data augmentation

Métrique	Validation
Accuracy	84,91 %
Précision COVID	84,65 %
Rappel COVID	86,70 %
F1 COVID	85,67 %
Rappel macro	86,72 %
F1 macro	85,83 %

M3 combine la data augmentation et l'oversampling du train (25 980 observations, soit 6 495 par classe). Il améliore M2 sur le rappel COVID (86,70 % contre 82,38 %) et le F1 COVID (85,67 % contre 79,83 %). Le rappel Viral Pneumonia atteint 94,64 %. Ces résultats restent ceux d'une seule exécution de validation.

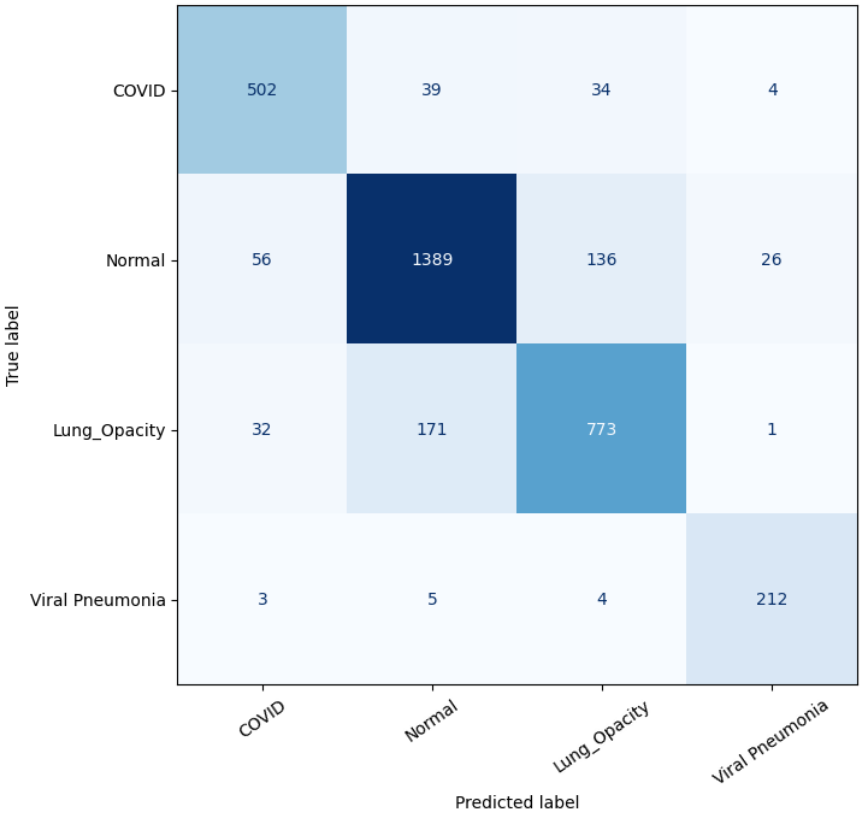


Figure — M3 : Matrice de confusion sur validation (issue du notebook).

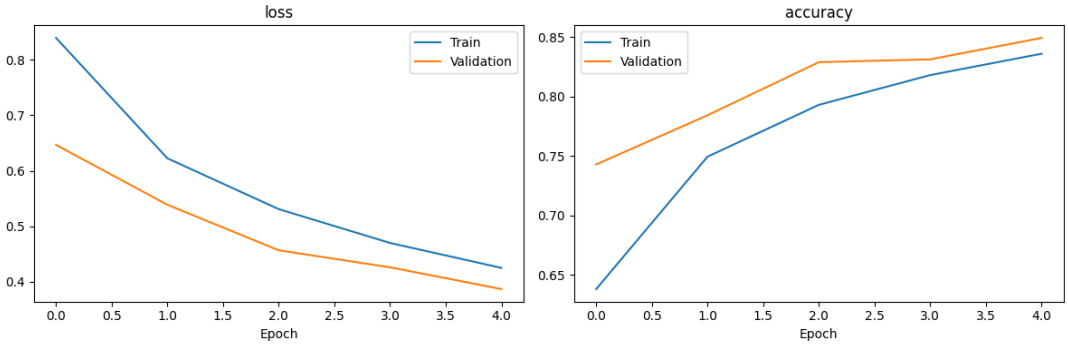
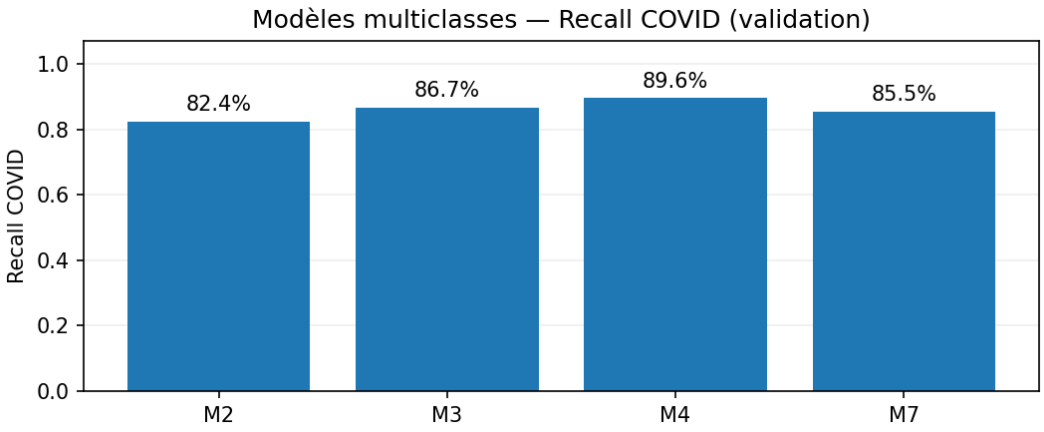


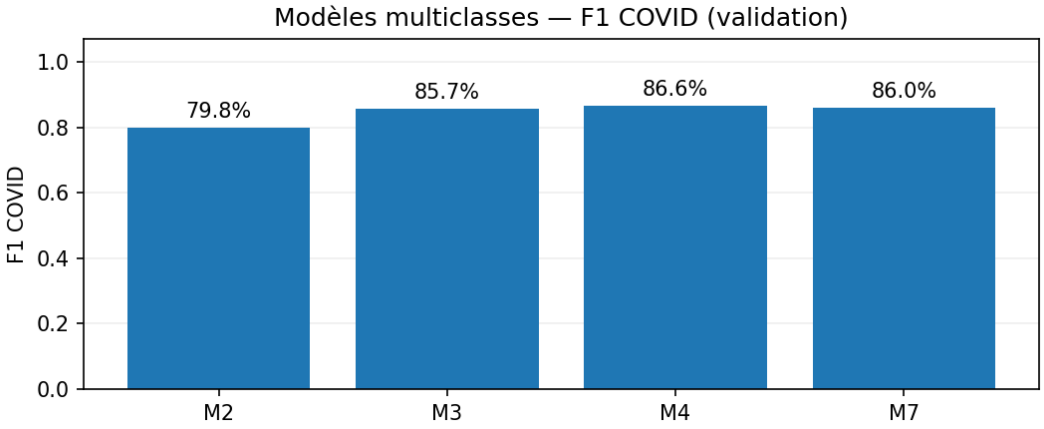
Figure — M3 : Courbes d'entraînement : loss et accuracy (issue du notebook).

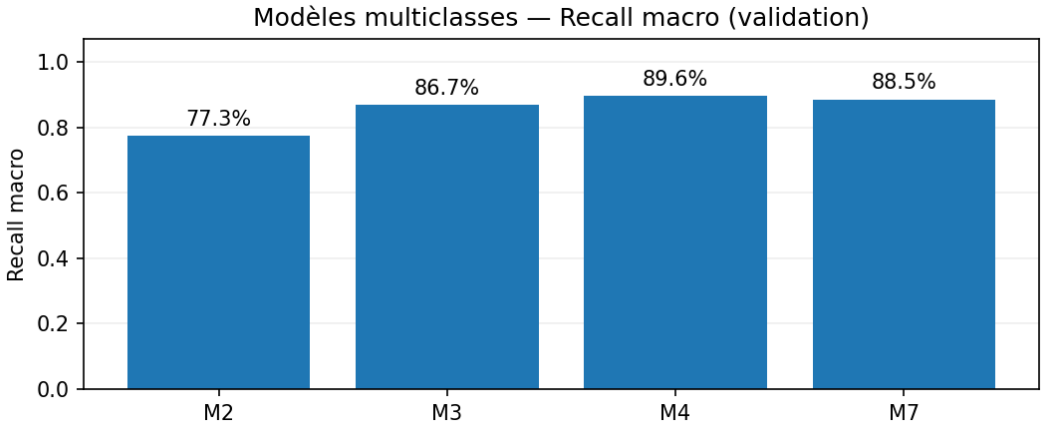
6.2 Comparaison des quatre modèles multiclasses

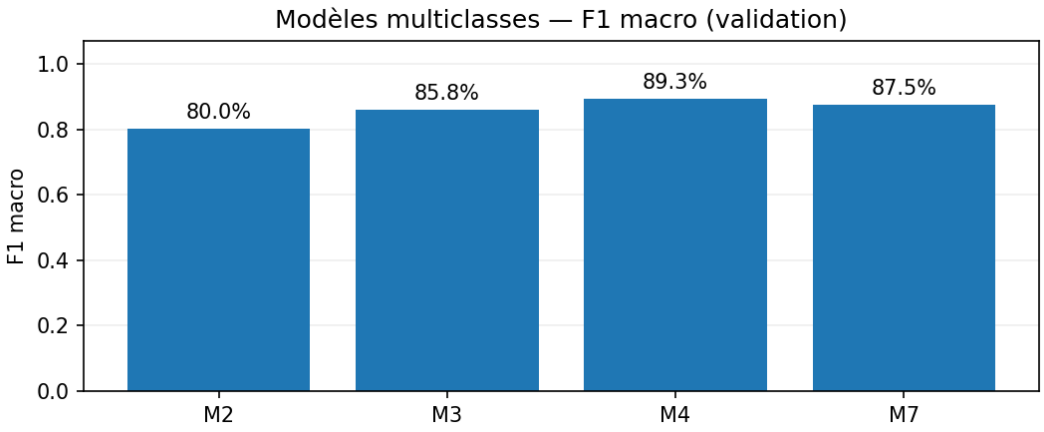
Modèle	Recall COVID	F1 COVID	Recall macro	F1 macro	Accuracy
M2 CNN + DA	82,38 %	79,83 %	77,30 %	80,03 %	81,43 %
M3 CNN + OS + DA	86,70 %	85,67 %	86,72 %	85,83 %	84,91 %
M4 VGG16	89,64 %	86,57 %	89,56 %	89,29 %	88,31 %
M7 VGG16 + OS + DA	85,49 %	86,01 %	88,51 %	87,53 %	87,19 %

M3 améliore M2 sur le recall COVID (86,70 % contre 82,38 %), le F1 COVID (85,67 % contre 79,83 %), le recall macro (86,72 % contre 77,30 %) et le F1 macro (85,83 % contre 80,03 %). M4 présente les meilleurs scores parmi les multiclasses sur ces quatre métriques : recall COVID 89,64 %, F1 COVID 86,57 %, recall macro 89,56 % et F1 macro 89,29 %. M7 reste proche de M4 mais ne l'améliore pas lors de cette exécution. Les résultats d'un entraînement unique par configuration ne suffisent pas à conclure à une supériorité générale.


Modèles multiclasses — Recall COVID (validation)
Recall COVID
1.0
0.8
0.6
0.4
0.2
0.0
82.4%
86.7%
89.6%
85.5%
M2
M3
M4
M7


Modèles multiclasses — F1 COVID (validation)
F1 COVID
1.0
0.8
0.6
0.4
0.2
0.0
79.8%
85.7%
86.6%
86.0%
M2
M3
M4
M7


Modèles multiclasses — Recall macro (validation)
Recall macro
1.0
0.8
0.6
0.4
0.2
0.0
77.3%
86.7%
89.6%
88.5%
M2
M3
M4
M7



Pour comparer les quatre modèles multiclasses, le rappel macro et le F1 macro complètent les scores COVID : ils rendent compte des performances sur l'ensemble des classes. Ces moyennes macro ne sont pas directement comparables aux moyennes macro d'une tâche binaire. Les résultats présentés ici concernent uniquement la validation ; ils ne préjugent pas des résultats finaux sur test.

7. Comparaison globale — détection de la classe COVID

Cette comparaison vise à examiner les performances de détection de la classe COVID des expériences binaires et multiclasses sur le même jeu de validation. Deux indicateurs communs sont retenus : le rappel COVID et le F1-score COVID. Les métriques macro des modèles multiclasses ont été analysées séparément en section 6.

7.1 Comparaison du recall et du F1 COVID

Expérience	Rappel COVID	F1 COVID
E0	85,70 %	86,00 %
E2	72,02 %	79,58 %
E3	**94,30 %**	87,01 %
E4	88,30 %	**≈ 90,1 %**
E6	74,60 %	82,60 %
E7	83,25 %	87,40 %
M2	82,38 %	79,83 %
M3	86,70 %	85,67 %
M4	89,64 %	86,57 %
M7	85,49 %	86,01 %

E3 présente le meilleur recall COVID (94,30 %), E4 le meilleur F1 COVID (90,1 %). M4 est le candidat multiclasses présentant le meilleur recall COVID (89,64 %) et F1 COVID (86,57 %) de cette famille. La comparaison doit tenir compte du coût des faux négatifs, des faux positifs et de l'intérêt éventuel de distinguer les autres pathologies.

7.2 Interprétation transversale et arbitrage

Un cas COVID prédit Non-COVID dans une tâche binaire, ou prédit comme l'une des trois autres classes dans une tâche multiclasses, compte dans les deux cas comme faux négatif COVID. Cette comparaison sur la classe COVID est donc pertinente sur le jeu de validation commun, même si les tâches et leurs sorties diffèrent. Elle ne démontre pas à elle seule la supériorité globale d'une architecture sur toutes les classes.

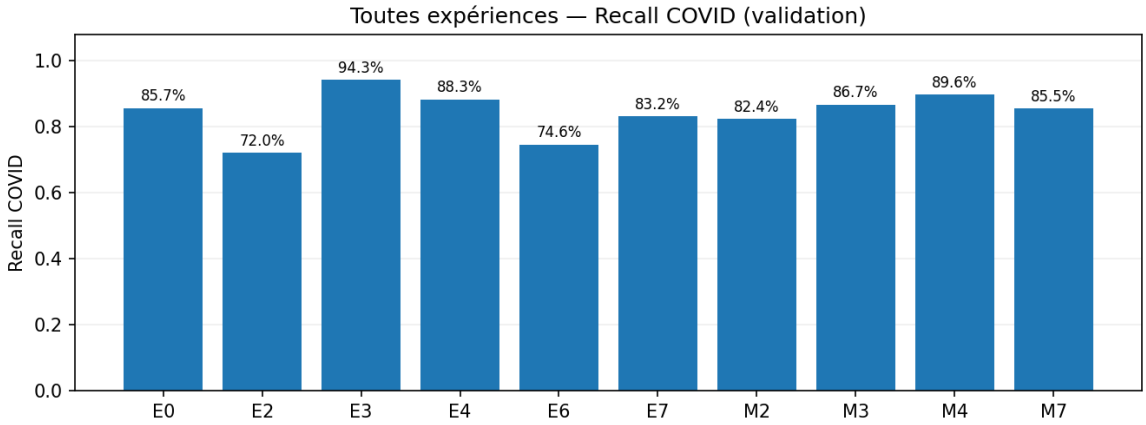


Figure — Comparaison cross-expériences : RECALL COVID sur validation..

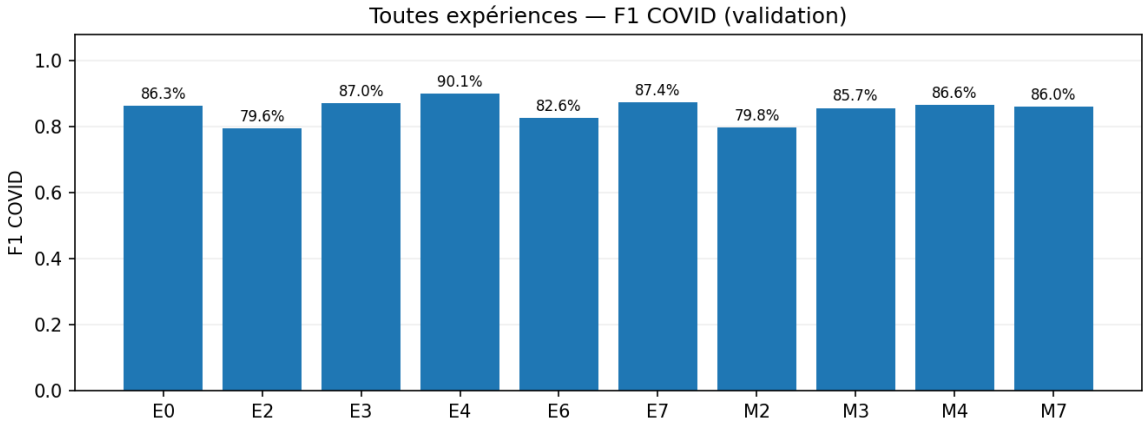


Figure — Comparaison cross-expériences : F1 COVID sur validation..

7.3 Comparaison des candidats et sélection pour optimisation

Option 1 — E3 : CNN binaire + oversampling + data augmentation. Meilleur recall COVID (94,30 %) ; 33 faux négatifs COVID, mais davantage de faux positifs (130).

Option 2 — E4 : VGG16 binaire sans OS/DA. Meilleur F1 COVID (environ 90,1 %) ; recall COVID 88,3 % ; 68 faux négatifs et 44 faux positifs.

Option 3 — M4 : VGG16 multiclasses sans OS/DA. Meilleur candidat multiclasses sur le recall COVID (89,64 %) et le F1 COVID (86,57 %) ; permet également de distinguer les quatre catégories.

Tableau de décision — métriques COVID sur le même jeu de validation (579 cas COVID).

Candidat	Tâche	Recall COVID	F1 COVID	Précision COVID
E3	Binaire	94,30 %	87,01 %	80,77 %
E4	Binaire	88,3 %	≈ 90,1 %	92,1 %
M4	Multiclasses	89,64 %	86,57 %	83,71 %

Synthèse de la présélection

La comparaison des performances sur validation conduit à approfondir trois approches complémentaires : E3, CNN binaire favorisant le rappel COVID ; E4, VGG16 binaire offrant un bon compromis précision–rappel ; et M4, VGG16 multiclasses permettant de distinguer les quatre catégories. Cette présélection est fondée uniquement sur la validation. Les optimisations et analyses d'interprétabilité sont présentées dans les chapitres suivants.

8. Optimisation des modèles

Cette section documente les configurations optimisées de E3, E4 et M4. Les comparaisons sont réalisées sur le jeu de validation stratifié commun (3 387 images, dont 579 COVID), sans utiliser le jeu de test pour choisir les hyperparamètres.

8.1 Optimisation Transfer Learning (TL) — E4 et M4

8.1.1 Protocole de fine-tuning

Les expériences E4 (VGG16 binaire) et M4 (VGG16 multiclasses) repartent des meilleurs checkpoints sauvegardés. Le bloc 5 de VGG16 est dégelé ; les autres blocs restent gelés. Le fine-tuning est effectué avec un learning rate de 1e-5, au plus 5 epochs, et un early stopping de patience 2. Pour M4, une deuxième phase poursuit l'entraînement depuis le meilleur checkpoint de phase 1 avec le même périmètre de couches dégelées et un learning rate réduit à 1e-6 (5 epochs maximum, patience 2). La phase 2 modifie donc aussi la durée cumulée d'entraînement, et pas seulement le learning rate.

Expérience	Recall COVID	F1 COVID	Accuracy globale
E4 initial (VGG16 binaire)	88,3 %	≈ 90,1 %	—
E4 fine-tuning bloc 5, LR 1e-5	96,03 %	96,78 %	98,91 %
M4 initial (VGG16 multiclasses)	89,64 %	86,57 %	—
M4 fine-tuning phase 1, LR 1e-5	95,34 %	96,08 %	93,36 %
M4 fine-tuning phase 2, LR 1e-6	95,51 %	97,02 %	93,71 %

Le premier fine-tuning de M4 apporte +5,70 points de recall COVID et +9,51 points de F1 COVID par rapport au modèle initial. La phase 2 apporte encore +0,17 point de recall et +0,94 point de F1 par rapport à la phase 1. L'accuracy globale des tâches binaire et multiclasses n'est pas directement comparable.

8.1.2 Optimisation du seuil de décision COVID sur validation

Les probabilités COVID ont été évaluées avec des seuils de 0,10 à 0,90 par pas de 0,05, sans réentraîner les modèles. Pour E4, la référence est le seuil binaire 0,50. Pour M4, la référence est la règle multiclasses argmax ; pour chaque seuil candidat, la classe COVID est retenue lorsque sa probabilité atteint le seuil, sinon la classe est choisie parmi les trois classes non-COVID. Les métriques ci-dessous ramènent les décisions à COVID versus non-COVID, sur les mêmes images.

Modèle / règle	Recall COVID	Précision COVID	F1 COVID	FN	FP
E4 seuil initial 0,50	96,03 %	97,54 %	96,78 %	23	14
E4 seuil 0,35	**96,89 %**	97,23 %	**97,06 %**	18	16
E4 seuil 0,15	98,10 %	94,20 %	96,11 %	11	35
M4 argmax initial	95,51 %	**98,57 %**	**97,02 %**	26	8
M4 seuil 0,35	96,03 %	97,89 %	96,95 %	23	12
M4 seuil 0,25	**96,72 %**	97,05 %	96,89 %	19	17
M4 seuil 0,10	97,24 %	94,78 %	95,99 %	16	31

Pour E4, le seuil 0,35 maximise le F1 COVID parmi les seuils testés et permet de détecter cinq cas COVID supplémentaires par rapport à 0,50, au prix de deux faux positifs supplémentaires. Pour M4, le meilleur F1 reste celui de la règle argmax initiale : le meilleur seuil balayé (0,35) n'améliore pas ce score. Abaisser le seuil de M4 augmente le rappel mais accroît les fausses alertes.

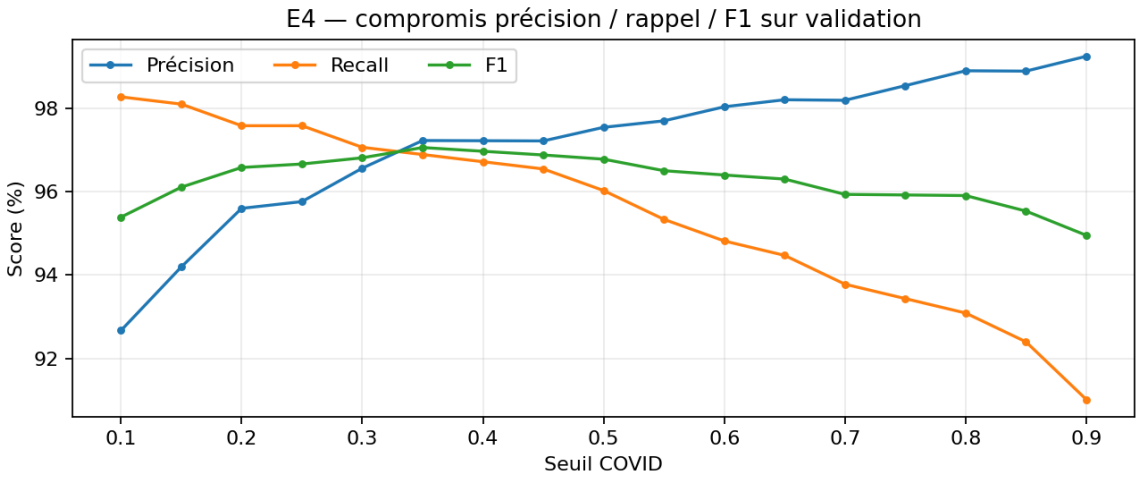


Figure — Évolution des métriques COVID en fonction du seuil pour E4 (jeu de validation).

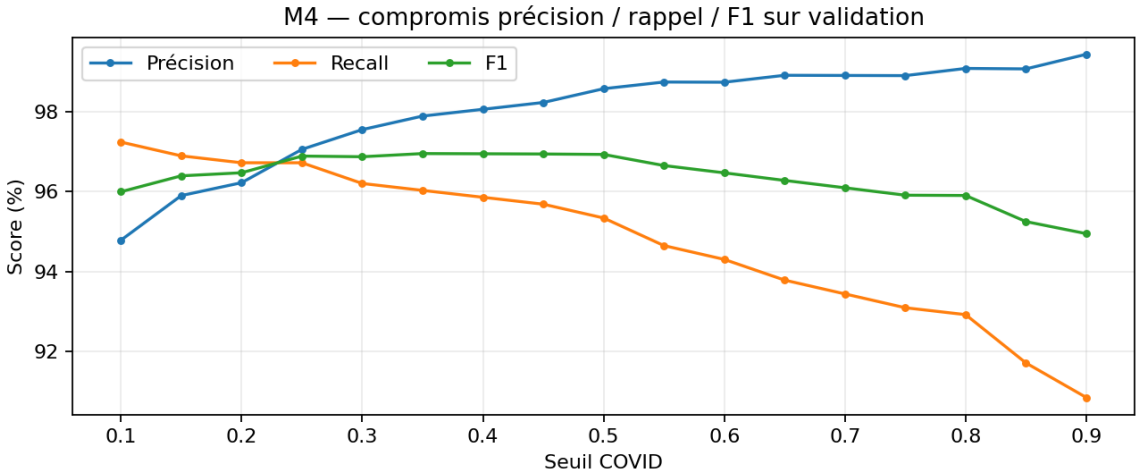


Figure — Évolution des métriques COVID en fonction du seuil pour M4 (jeu de validation).

8.1.3 Comparaison des compromis E4 / M4 sur validation

Le tableau distingue les configurations finalement retenues des variantes examinées pendant l'optimisation. E4 présente le meilleur rappel COVID et le meilleur F1 COVID parmi les configurations indiquées. M4 reste pertinent pour sa capacité à différencier quatre classes et pour l'analyse Grad-CAM comparative. Pour E3, l'optimisation ne surpasse pas la version initiale sur les critères COVID prioritaires : c'est donc E3 initial qui est conservé pour l'évaluation finale sur test.

Les performances de validation ne permettent pas de départager définitivement E4 et M4 : E4 privilégie la détection binaire, tandis que M4 distingue quatre classes. Nous retenons donc les deux modèles pour l'analyse d'interprétabilité par Grad-CAM, afin de comparer leurs prédictions et les régions de l'image mobilisées sur un même échantillon de validation.

8.2 Optimisation CNN — E3

8.2.1 Architecture et stratégie d'optimisation

L'optimisation d'E3 a consisté à modifier l'architecture et la stratégie d'entraînement du CNN initial, sans modifier le découpage commun train/validation/test. Le CNN optimisé comprend quatre blocs convolutionnels successifs (32, 64, 128 et 256 filtres, noyaux 3 × 3), avec Batch Normalization et MaxPooling. La tête de classification utilise une couche Dense de 256 neurones, un Dropout de 0,5 et une sortie sigmoïde ; le modèle compte 9 828 481 paramètres. Une régularisation L2 de 1e-5 est appliquée. L'entraînement utilise Adam (learning rate 1e-5), la binary cross-entropy, au plus cinq epochs, un EarlyStopping (patience 3), un ModelCheckpoint fondé sur val_loss et ReduceLROnPlateau (facteur 0,5, patience 3). L'objectif est d'évaluer si cette configuration améliore les résultats COVID sur validation, et non de sélectionner sur le test.

Élément	Configuration E3 optimisée

Entrée	224 × 224, niveaux de gris
Convolutions	4 blocs, filtres 32 / 64 / 128 / 256, noyaux 3 × 3
Régularisation	L2 = 1e-5 ; Batch Normalization ; Dropout = 0,5
Optimiseur et perte	Adam, learning rate = 1e-5 ; binary cross-entropy
Entraînement	5 epochs maximum ; EarlyStopping patience 3
Callbacks	ModelCheckpoint sur val_loss ; ReduceLROnPlateau facteur 0,5, patience 3
Décision	Sigmoïde, seuil 0,5

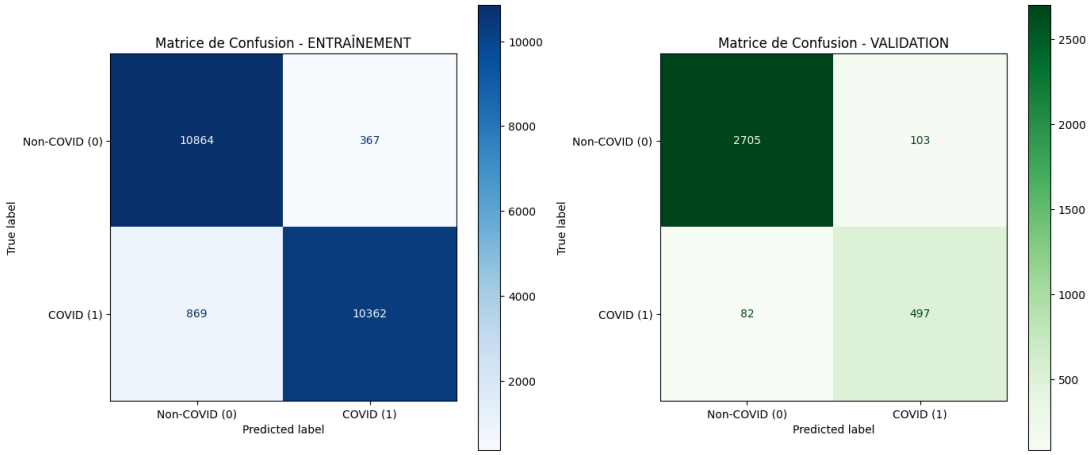
8.2.2 Résultats de validation et comparaison

Expérience	Recall COVID	Précision COVID	F1 COVID	Accuracy globale
E3 initial	94,30 %	80,77 %	87,01 %	95,19 %
E3 optimisé	≈ 86 %	≈ 83 %	≈ 84 %	≈ 95 %

Les deux configurations sont comparées sur le même jeu de validation, avec les métriques COVID prioritaires. Les valeurs de la version optimisée proviennent du rapport de classification enregistré dans le notebook et sont arrondies : les écarts ne doivent pas être interprétés au centième de point.

La version optimisée obtient une précision COVID légèrement supérieure, mais un rappel et un F1 COVID inférieurs à ceux d'E3 initial. Le meilleur checkpoint optimisé est enregistré à l'époque 4, selon val_loss (0,13945 ; val_accuracy 94,54 %). Plusieurs modifications — architecture, régularisation et paramètres d'entraînement — ayant été évaluées ensemble, ces résultats ne permettent pas d'attribuer la baisse à un changement isolé. Ils suffisent néanmoins à écarter cette variante pour la sélection finale fondée sur la validation.

Figure 9.2-A — Matrices de confusion E3 optimisé : entraînement et validation.



8.2.3 Bilan de l'optimisation E3

L'optimisation du CNN E3 n'a pas amélioré les critères COVID prioritaires sur le jeu de validation : le rappel passe de 94,30 % pour E3 initial à environ 86 % pour E3 optimisé, et le F1 COVID de 87,01 % à environ 84 %. La version optimisée est donc conservée comme expérience méthodologique, mais non sélectionnée pour l'évaluation finale. C'est le CNN E3 initial, retenu sur la base de la validation, qui est évalué sur le jeu de test. Une évaluation supplémentaire d'E3 optimisé sur test n'est pas prévue.

8.3 Synthèse comparative des optimisations

Configuration retenue ou évaluée	Recall COVID (validation)	F1 COVID (validation)	Décision
E4 fine-tuné, seuil 0,35	96,89 %	97,06 %	Retenu pour le test et Grad-CAM
M4 fine-tuné, argmax	95,51 %	97,02 %	Retenu pour comparaison ; seuil 0,25 également étudié

E3 initial	94,30 %	87,01 %	Retenu pour le test
E3 optimisé	≈ 86 %	≈ 84 %	Non retenu

Sur validation, E4 fine-tuné au seuil 0,35 présente un rappel COVID de 96,89 % et un F1 de 97,06 %. M4 fine-tuné en argmax atteint un rappel de 95,51 % et un F1 de 97,02 %. Pour E3, l'optimisation réduit le rappel COVID d'environ 94,30 % à 86 % et le F1 de 87,01 % à environ 84 %. La variante initiale est donc retenue pour l'évaluation finale, tandis que l'optimisation est documentée comme une expérimentation non retenue.

9. Interprétabilité des modèles — Grad-CAM

9.1 Interprétabilité du modèle E4

9.1.1 Objectif et protocole

L'objectif est d'examiner les régions de l'image qui contribuent positivement au score COVID du modèle E4 (VGG16 binaire) fine-tuné. Grad-CAM est appliqué sans réentraîner le modèle, sur la dernière couche convolutive de VGG16 (block5_conv3), en calculant les gradients du score COVID par rapport aux cartes d'activation, puis une combinaison pondérée de ces cartes. Les cartes obtenues sont normalisées et superposées aux radiographies d'origine.

Le seuil 0,35 sert uniquement à classer les images en COVID/non-COVID pour sélectionner les cas ; il ne modifie pas les cartes Grad-CAM. Les 3 387 images de validation sont utilisées avec le même prétraitement VGG16 que lors de l'évaluation. Le jeu de test n'est pas utilisé.

9.1.2 Vérifications de cohérence et échantillon

Le checkpoint E4 et la reconstruction du chemin de calcul Grad-CAM produisent des probabilités identiques sur les exemples contrôlés (différence maximale mesurée : 0,0). Les prédictions sur validation retrouvent exactement la matrice de confusion du modèle E4 au seuil 0,35 : 561 vrais positifs (TP), 18 faux négatifs (FN), 16 faux positifs (FP) et 2 792 vrais négatifs (TN), dont 579 cas COVID au total.

Onze radiographies ont été tirées de manière reproductible au sein des quatre catégories : 3 TP, 3 FN, 3 FP et 2 TN. Les six figures ci-dessous montrent deux exemples de TP, deux FN et deux FP. Cette sélection est illustrative et ne constitue pas une analyse statistique exhaustive de l'attention du réseau.

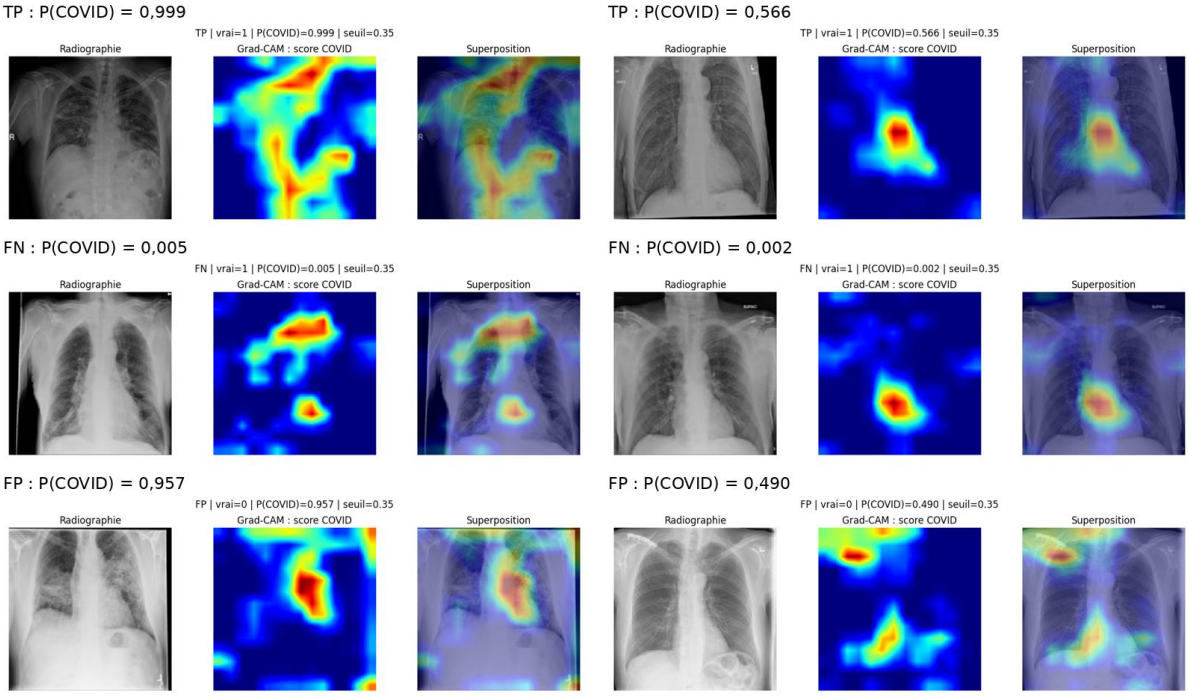


Figure — Exemples Grad-CAM E4 sur validation : radiographie, carte de chaleur du score COVID et superposition. TP = vrai positif ; FN = faux négatif ; FP = faux positif. Les valeurs affichées sont les probabilités COVID produites par le modèle.

9.1.3 Observations et limites

Les exemples de vrais positifs présentent des activations parfois localisées dans les champs pulmonaires, mais également dans des zones supérieures ou périphériques de l'image. Les faux négatifs peuvent présenter des régions mises en évidence alors

même que leur score COVID est très faible : une activation visuellement forte sur une carte normalisée ne garantit donc pas une prédiction correcte. Dans plusieurs faux positifs, les régions mises en évidence incluent des structures pulmonaires et des zones proches des bords ou du haut de l'image.

Ces observations soulèvent la possibilité que le modèle exploite, au moins pour certaines images, des caractéristiques non spécifiques à une pathologie pulmonaire (cadrage, annotations, contraste, artefacts de provenance). Elles ne suffisent cependant pas à démontrer un biais particulier ni à identifier une lésion. Grad-CAM fournit une indication spatiale approximative, non une preuve causale ou une validation clinique. La carte est de résolution réduite et agrandie pour l'affichage ; sa normalisation image par image empêche de comparer directement l'intensité absolue entre deux radiographies.

9.1.4 Bilan de l'analyse E4

L'analyse Grad-CAM E4 a été conduite sur validation et les contrôles de cohérence du calcul ont été documentés. Certaines activations apparaissent hors des champs pulmonaires, ce qui justifie une interprétation prudente. Les performances E4 sur le jeu de test sont présentées en section 11 ; les visualisations ne suffisent pas à démontrer que le modèle apprend exclusivement des caractéristiques pulmonaires pertinentes.

9.2 Interprétabilité du modèle M4

Le modèle M4, VGG16 multiclasses fine-tuné, a été analysé par Grad-CAM en expliquant le score associé à la classe COVID. Les cartes sont calculées sur les mêmes 11 radiographies de validation que celles examinées pour E4. Certaines activations se situent dans les champs pulmonaires ; d'autres apparaissent dans des régions périphériques ou proches des bordures. Ces observations invitent à considérer le risque de corrélations visuelles parasites, sans permettre de le quantifier.

La comparaison image par image et les exemples illustrés figurent en section 10.3. La sélection des 11 images a été définie à partir des prédictions d'E4 : elle n'est donc pas un échantillon représentatif des erreurs propres à M4.

9.3 Comparaison qualitative E4 / M4

9.3.1 Méthode et contrôles

Une analyse Grad-CAM complémentaire a été réalisée sur M4 (VGG16 multiclasses après fine-tuning phase 2), en réutilisant exactement les 11 radiographies de validation retenues pour E4, dans le même ordre : 3 vrais positifs, 3 faux négatifs, 3 faux positifs et 2 vrais négatifs selon les prédictions d'E4 au seuil 0,35. Les catégories TP/FN/FP/TN correspondent donc à E4, pas nécessairement à M4. La classe expliquée par Grad-CAM est COVID pour les deux modèles. Le chemin de calcul Grad-CAM M4 reproduit les prédictions du modèle chargé (différence maximale observée : 0,0). Les poids des modèles ne sont pas modifiés.

9.3.2 Comparaison des prédictions sur les mêmes images

Sur ces 11 images sélectionnées à partir des erreurs et succès d'E4, les décisions binaires COVID / non-COVID concordent pour 9 images sur 11. Les deux désaccords sont favorables à M4 : l'image 2603 (COVID réel) est manquée par E4 [P(COVID)=0,055] mais reconnue par M4 [P(COVID)=0,546, classe prédite COVID] ; l'image 3138 (non-COVID réel) est classée COVID par E4 [P(COVID)=0,490] mais Normal par M4 [P(COVID)=0,380]. Cette sélection n'est pas représentative d'une évaluation comparative globale : elle a été définie en fonction des résultats d'E4.

Index validation	Vérité COVID	Décision E4	Décision M4	P(COVID) E4 / M4
2603	Oui	Non-COVID	COVID	0,055 / 0,546
3138	Non	COVID	Normal	0,490 / 0,380
1095	Non	COVID	COVID	0,957 / 0,953
2365	Non	COVID	COVID	0,938 / 0,959

9.3.3 Lecture qualitative des cartes Grad-CAM M4

Les cartes M4 montrent des comportements hétérogènes : certaines activations se trouvent dans les champs pulmonaires, mais d'autres se concentrent sur des zones centrales, apicales ou périphériques, parfois près des annotations ou des bordures. En particulier, sur l'image 2365, faussement classée COVID par les deux modèles, la carte M4 présente une activation forte près du bord supérieur droit, hors de la zone pulmonaire principale. Sur l'image 3138, M4 classe correctement Normal malgré une carte de contribution au score COVID comportant des activations périphériques. Il serait donc excessif de conclure que M4 est systématiquement plus pertinent médicalement ou plus robuste qu'E4.

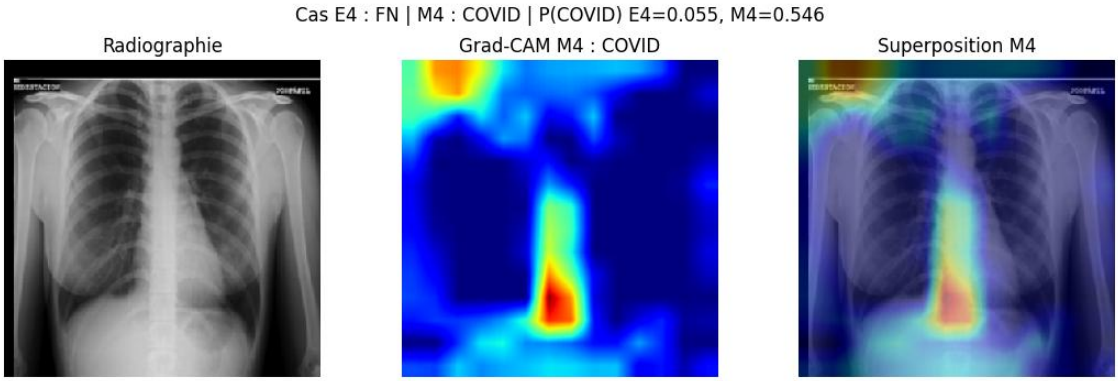


Image 2603 — COVID réel : E4 faux négatif ; M4 prédit COVID. Grad-CAM M4 pour le score COVID.

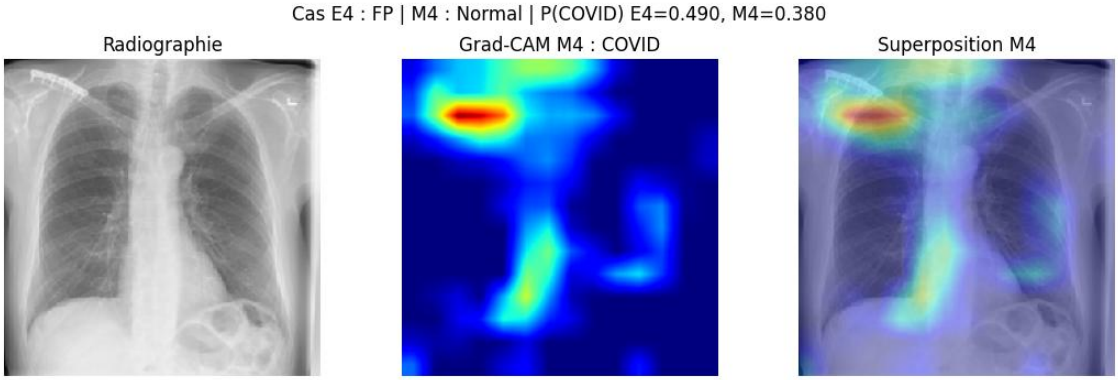


Image 3138 — non-COVID réel : E4 faux positif ; M4 prédit Normal. Grad-CAM M4 pour le score COVID.

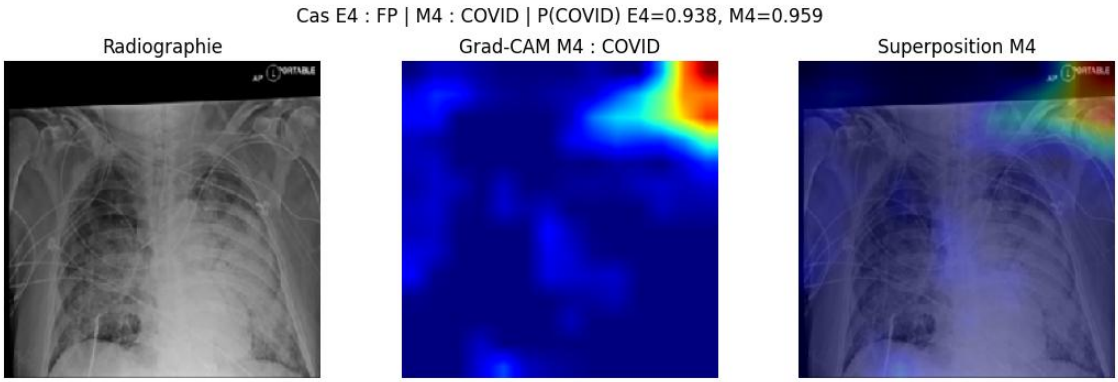


Image 2365 — non-COVID réel : faux positif pour les deux modèles ; activation M4 marquée dans la région supérieure droite.

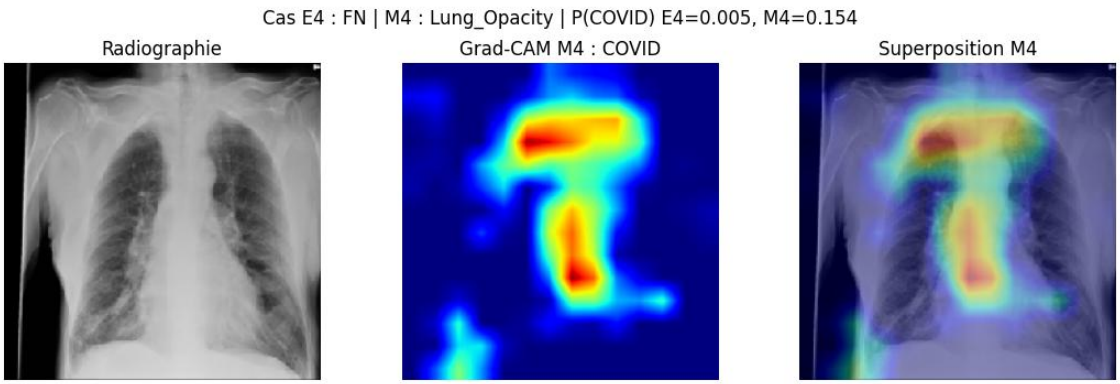


Image 356 — COVID réel : faux négatif E4 et M4 (M4 : Lung_Opacity).

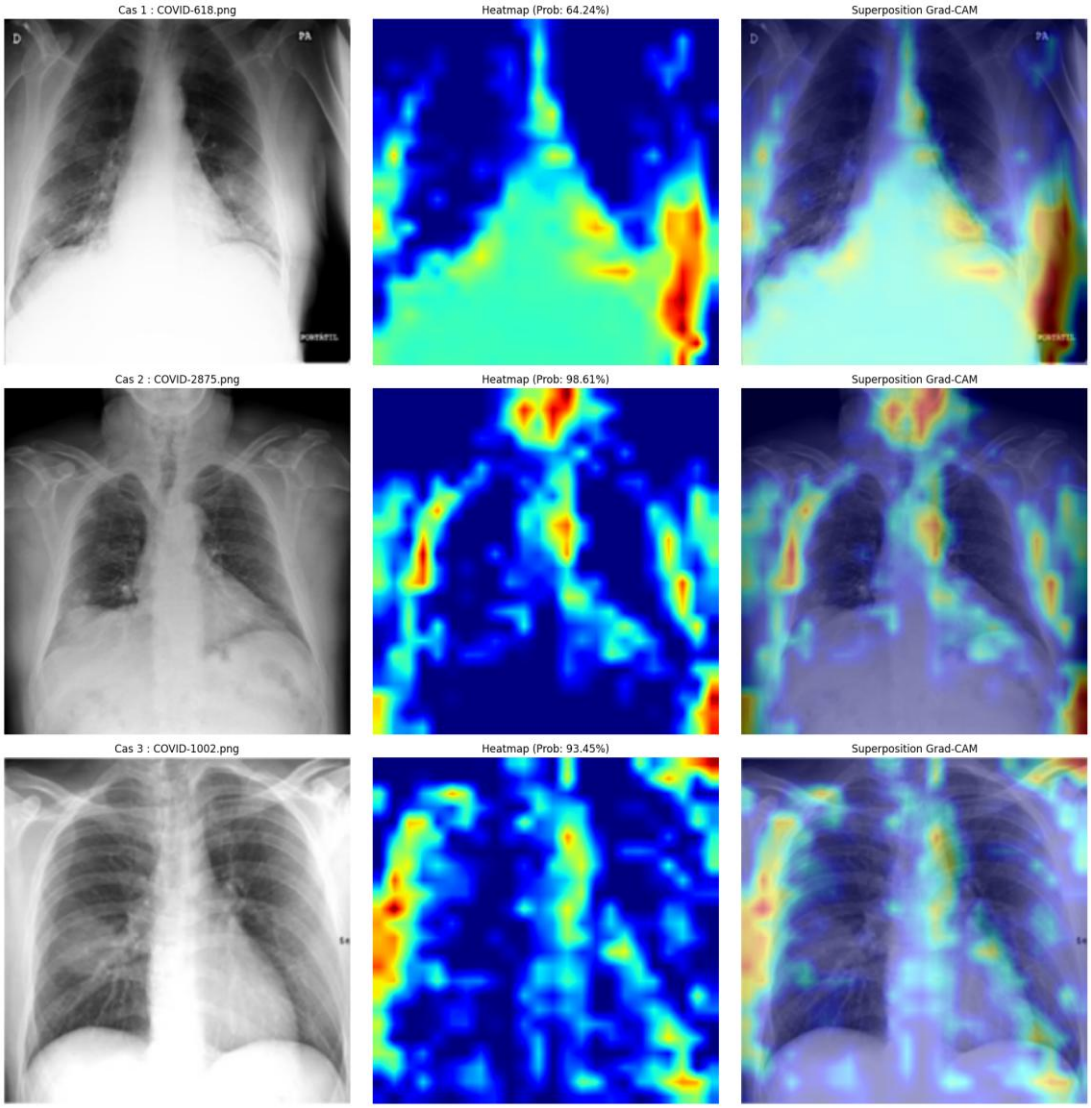
9.3.4 Conclusion et limites

L'analyse des mêmes 11 radiographies permet une comparaison qualitative contrôlée : M4 corrige deux erreurs d'E4 sur cet échantillon. Cette observation ne démontre pas une meilleure généralisation de M4. Les cartes Grad-CAM constituent des indications approximatives de sensibilité, non des preuves de causalité ou de pertinence clinique. Des activations hors des champs pulmonaires ont été observées pour les deux modèles ; une validation externe et des contrôles ciblés des artefacts seraient nécessaires pour évaluer leur robustesse.

9.4 Interprétabilité du CNN E3 optimisé

Grad-CAM a été appliqué au CNN E3 optimisé sur la dernière couche convolutionnelle (conv2d_3). Les radiographies sont redimensionnées en 224 × 224, converties en niveaux de gris et normalisées par 255. La visualisation associe radiographie d'origine, carte de chaleur et superposition ; elle permet d'observer les zones contribuant au score COVID, sans constituer une justification médicale du diagnostic.

Figure 10.4 — Exemples Grad-CAM du CNN E3 optimisé sur trois cas COVID de validation.



Les visualisations sont qualitatives et portent sur un petit nombre d'exemples. Elles ne constituent pas une mesure de robustesse de l'interprétabilité. Une comparaison systématique avec les erreurs de classification et une vérification des activations hors des champs pulmonaires resteraient nécessaires.

L'analyse E3 repose sur quelques cas illustratifs et n'a pas fait l'objet du protocole comparatif à 11 images appliqué aux modèles VGG16. Elle ne permet donc pas de conclure à une meilleure localisation des indices pulmonaires pour E3.

L'interprétation de ces cartes doit être distinguée de la sélection du modèle : les Grad-CAM E3 présentés ici ont été calculés sur le CNN optimisé, tandis que les résultats finaux sur test portent sur le CNN E3 initial. Les visualisations ne peuvent donc pas être

attribuées au modèle initial sans nouvelle analyse. Le faible nombre d'images étudiées limite également toute comparaison directe avec les onze cas communs à E4 et M4.

9.5 Synthèse transversale et pistes d'amélioration

Les analyses Grad-CAM des trois approches mettent en évidence des zones d'activation parfois situées en dehors des champs pulmonaires. Pour E4 et M4, les mêmes onze images permettent une comparaison qualitative, mais cet échantillon ne suffit pas à établir une hiérarchie de fiabilité des explications. Pour E3, le protocole et le checkpoint analysé sont différents : aucune comparaison quantitative de localisation ne peut être déduite de ces figures.

Les pistes d'amélioration sont de vérifier systématiquement la présence d'indices hors poumons (bordures, annotations, contraste et provenance), d'étendre l'analyse à un échantillon plus large et stratifié incluant les erreurs de chaque modèle, d'examiner les cartes avec un avis clinique et, si nécessaire, d'évaluer des stratégies de cadrage ou de segmentation pulmonaire. Une validation sur des données externes serait également nécessaire avant toute interprétation clinique des performances.

10. Évaluation finale sur le jeu de test

L'évaluation finale porte sur les trois approches sélectionnées à partir de la validation : le CNN E3 initial, E4 (VGG16 binaire) et M4 (VGG16 multiclasses). Le CNN E3 optimisé, moins performant sur les critères COVID prioritaires en validation, n'a pas été retenu pour cette étape.

10.1 Protocole de l'évaluation finale

Le jeu de test tenu à l'écart des entraînements et de la sélection comprend 4 233 radiographies : 723 COVID, 1 140 Lung_Opacity, 2 090 Normal et 280 Viral Pneumonia (3 510 non-COVID). Les modèles et règles de décision ont été fixés à partir de la validation avant toute inférence sur le test. Aucune optimisation ni réentraînement n'a été effectué sur le test.

E4 : checkpoint E4_FT_B5_LR1e-5_best.keras (fine-tuning du bloc 5 VGG16), sortie sigmoïde, COVID si probabilité ≥ 0,35.

M4 : checkpoint M4_FT2_B5_LR1e-6_best.keras (fine-tuning phase 2), sortie softmax quatre classes, prédiction par argmax.

Prétraitement commun E4/M4 : RGB 224 × 224, tf.keras.applications.vgg16.preprocess_input, ordre des images conservé (shuffle=False).

E3 — évaluation binaire : 4 233 images de test, dont 3 510 Non-COVID et 723 COVID ; images en niveaux de gris, redimensionnées au format du modèle et normalisées par 1/255 ; seuil de classification de 0,5 ; shuffle=False. Le checkpoint utilisé pour le test E3 a été confirmé par le binôme : E3_CNN_best.keras (CNN E3 initial).

Le binôme confirme que le test E3 utilise le checkpoint « E3_CNN_best.keras » du CNN initial. La variante optimisée n'a pas été retenue sur validation et n'a pas fait l'objet d'une évaluation sur test.

10.2 Résultats binaires sur test

Indicateur	E4 (seuil 0,35)	M4 (argmax)
Accuracy	98,82 %	98,80 %
Précision COVID	95,66 %	96,67 %
Rappel COVID	97,51 %	96,27 %
F1 COVID	96,58 %	96,47 %
Vrais positifs (TP)	705	696
Faux négatifs (FN)	18	27
Faux positifs (FP)	32	24
Vrais négatifs (TN)	3 478	3 486

Matrices de confusion binaires (lignes : réel non-COVID / COVID ; colonnes : prédit non-COVID / COVID) : E4 [[3478, 32], [18, 705]] ; M4 [[3486, 24], [27, 696]].

E4 détecte neuf cas COVID supplémentaires parmi les 723 cas positifs, au prix de huit fausses alertes supplémentaires. Son rappel est supérieur de 1,24 point de pourcentage ; M4 conserve une précision supérieure de 1,01 point. L'écart de F1 COVID n'est que de 0,11 point. Ces écarts descriptifs ne démontrent pas une supériorité statistique générale.

Résultats E3 sur test (évaluation fournie le 6 novembre 2026)

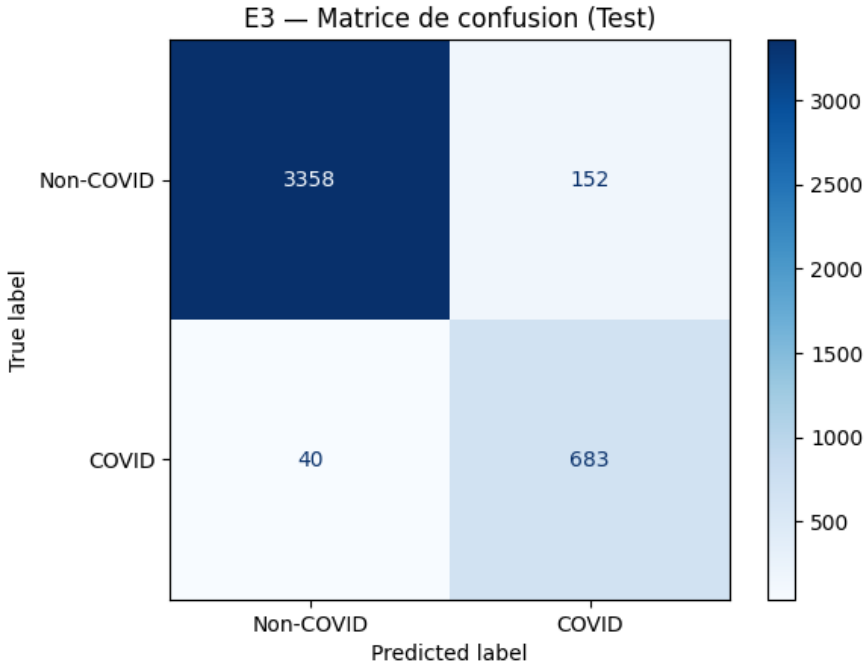
Sur 4 233 images de test, E3 classe correctement 3 358 images Non-COVID et 683 images COVID. Il produit 152 faux positifs et 40 faux négatifs. L'accuracy globale atteint 95,46 %, avec un rappel COVID de 94,47 % et un F1 COVID de 87,68 %. Ces résultats décrivent la performance sur ce jeu de test et ne constituent pas une validation clinique.

Métrique	Non-COVID	COVID
Précision	98,82 %	81,80 %
Rappel	95,67 %	94,47 %
F1-score	97,22 %	87,68 %
Support	3 510	723

Matrice de confusion E3 sur test — lignes : classe réelle ; colonnes : classe prédite.

Réel / Prédit	Non-COVID	COVID
Non-COVID	3 358	152
COVID	40	683

Figure — Matrice de confusion E3 sur le jeu de test (sortie enregistrée du notebook).



Comparaison indicative E3 initial : sur validation, le notebook « E3_model-correct » indique un rappel COVID de 94,30 %, une précision de 80,77 %, un F1 COVID de 87,01 % et une accuracy de 95,19 %. Sur test, « test-final.ipynb » rapporte respectivement 94,47 %, 81,80 %, 87,68 % et 95,46 %. Le checkpoint E3 initial utilisé sur test a été confirmé par le binôme.

Le binôme a confirmé le checkpoint E3 initial et signalé des erreurs de transcription dans son PDF antérieur. Les métriques de validation retenues proviennent du notebook E3 initial (rappel 94,30 %, précision 80,77 %, F1 87,01 %, accuracy 95,19 %). La précision COVID de 98,78 % évoquée dans son message ne concorde pas avec ce notebook et n'est pas reprise.

10.3 Résultats multiclasses sur test

Classe	Précision	Rappel	F1
COVID	96,67 %	96,27 %	96,47 %
Lung_Opacity	91,01 %	89,65 %	90,32 %
Normal	93,89 %	94,83 %	94,36 %
Viral Pneumonia	96,77 %	96,43 %	96,60 %

Macro-moyenne	94,58 %	94,29 %	94,44 %

Accuracy multiclasses : 93,79 %. Matrice de confusion M4 (ordre COVID, Lung_Opacity, Normal, Viral Pneumonia) : [[696,11,14,2],[9,1022,109,0],[12,89,1982,7],[3,1,6,270]]. Les principales confusions opposent Lung_Opacity et Normal : 109 cas Lung_Opacity prédits Normal et 89 cas Normal prédits Lung_Opacity.

10.4 Stabilité validation / test et choix final

Indicateur	Validation	Test
E3 initial — rappel COVID	**94,30 %**	**94,47 %**
E3 initial — F1 COVID	87,01 %	87,68 %
E3 initial — précision COVID	80,77 %	81,80 %
E3 initial — accuracy globale	95,19 %	95,46 %
E4 rappel COVID	96,89 %	97,51 %
E4 F1 COVID	97,06 %	96,58 %
M4 rappel COVID	95,51 %	96,27 %
M4 F1 COVID	97,02 %	96,47 %

Le checkpoint du test E3 a été confirmé par le binôme comme étant « E3_CNN_best.keras » (CNN initial).

Sur le jeu de test interne de 4 233 radiographies (dont 723 COVID), les trois modèles retenus ont été évalués. E3 présente une accuracy de 95,46 %, un rappel COVID de 94,47 % (683 vrais positifs, 40 faux négatifs) et un F1 COVID de 87,68 %. Ces résultats sont cohérents avec les performances de validation du CNN E3 initial (accuracy 95,19 %, rappel COVID 94,30 %, F1 COVID 87,01 %), le binôme ayant confirmé l'utilisation du checkpoint de la version initiale. E4, au seuil de 0,35, détecte 705 cas COVID (18 faux négatifs, 32 faux positifs) ; M4, en argmax, en détecte 696 (27 faux négatifs, 24 faux positifs) tout en distinguant quatre classes. E4 présente donc le rappel COVID le plus élevé sur ce test, M4 produit moins de faux positifs COVID, et E3 constitue la référence CNN spécifique. Les résultats illustrent des compromis entre approches et tâches de classification ; aucun modèle n'est désigné comme supérieur dans tous les usages. Le jeu de test n'a servi ni à réoptimiser les seuils ni à sélectionner les variantes.

11. Discussion et limites

Les expériences mettent en évidence des compromis entre CNN conçu spécifiquement et transfert d'apprentissage, ainsi qu'entre classification binaire et multiclasses. Pour E3, l'optimisation réduit le rappel COVID sur validation (94,30 % pour E3 initial contre environ 86 % après optimisation) et le F1 COVID (87,01 % contre environ 84 %). Cette variante n'a donc pas été sélectionnée pour le test final. Les résultats du test E3 transmis (rappel COVID 94,47 %) sont présentés comme ceux du modèle initial, le checkpoint ayant été confirmé par le binôme.

Les modèles VGG16 fine-tunés E4 et M4 présentent des performances COVID élevées sur validation et sur test interne. E4 détecte davantage de cas COVID sur test ; M4 génère moins de fausses alertes COVID et distingue les quatre classes. Ces propriétés répondent à des objectifs différents : la détection binaire et la différenciation multiclasses ne se résument pas à un unique classement.

L'analyse Grad-CAM révèle des activations parfois situées en dehors des champs pulmonaires, notamment sur des zones périphériques, des annotations ou des régions de cadrage. Ces observations suggèrent un risque de corrélations visuelles parasites, mais ne permettent ni de quantifier ce risque ni d'affirmer qu'il explique les prédictions. L'analyse E3 repose sur quelques exemples, tandis que la comparaison E4/M4 utilise onze images sélectionnées à partir des résultats E4 : ces échantillons sont illustratifs et non représentatifs de l'ensemble des erreurs.

La validation et le test proviennent du même corpus d'images. Ils permettent d'apprécier la généralisation sur ce partage interne, sans démontrer une robustesse à d'autres établissements, appareils, protocoles d'acquisition ou populations. L'étude n'inclut ni validation externe, ni évaluation prospective, ni validation clinique. En conséquence, les résultats ne permettent pas de recommander un usage diagnostique réel.

Les prolongements les plus utiles seraient une évaluation externe indépendante, un audit des artefacts et de la provenance des images, une analyse des erreurs par sous-population et une étude de la sensibilité des Grad-CAM à des recadrages ou masquages des zones non pulmonaires. Ces propositions constituent des perspectives et non des expériences réalisées dans le projet.

12. Conclusion et perspectives

Ce projet a comparé des approches de classification de radiographies thoraciques pour identifier la classe COVID, en formulation binaire et multiclasses. Les expériences initiales ont permis de sélectionner un CNN E3, un VGG16 binaire E4 et un VGG16 multiclasses M4, puis d'étudier leur optimisation et l'interprétabilité de leurs prédictions.

Le fine-tuning des modèles E4 et M4 a conduit à des performances élevées sur validation. Sur le test interne de 4 233 radiographies, E4 présente moins de faux négatifs COVID que M4 (18 contre 27), tandis que M4 présente moins de faux positifs COVID (24 contre 32) et distingue quatre classes. Pour le CNN E3, la variante initiale a été sélectionnée sur validation, l'optimisation ayant dégradé les critères COVID prioritaires ; elle est donc la seule variante E3 considérée pour le test final. Le résultat de test E3 correspond au checkpoint confirmé de l'identité du checkpoint. Aucun modèle n'est déclaré supérieur pour tous les usages.

Au-delà des scores, l'étude Grad-CAM met en évidence la nécessité d'examiner les indices visuels exploités par les modèles et de ne pas assimiler une bonne performance sur un corpus à une pertinence clinique démontrée. Les perspectives prioritaires sont la validation externe, l'analyse des biais de provenance et l'étude plus systématique des erreurs. Le travail constitue une expérimentation de deep learning sur un jeu de données défini, et non un dispositif médical validé.

13. Références et annexes

Source complémentaire E3 : « test-final.ipynb » et « rapport de jeu de test final.pdf », transmis le 6 novembre 2026. Les métriques E3 sur test et les graphiques correspondants proviennent de ces fichiers ; le checkpoint E3_CNN_best.keras a été confirmé par le binôme.

Les éléments de traçabilité suivants sont identifiables dans le rapport et les notebooks du projet. Ils sont répertoriés pour permettre la reproduction et la vérification des expériences ; ils ne remplacent pas les références bibliographiques complètes des sources originales.

Corpus : radiographies réparties en quatre catégories — COVID, Lung_Opacity, Normal et Viral Pneumonia. Les répartitions et le protocole de séparation sont documentés en sections 2 et 3. La référence bibliographique exacte du corpus et ses conditions de licence restent à confirmer à partir de la source originale.

Méthodes et logiciels mobilisés : CNN convolutifs, VGG16 et transfert d'apprentissage, Grad-CAM, TensorFlow/Keras et outils de calcul des métriques de classification. Les expérimentations ont été menées dans des environnements distincts ; les versions exactes des bibliothèques ne sont pas systématiquement archivées. Les notebooks et paramètres des modèles constituent les principaux éléments de reproductibilité.

Traçabilité E3 : « E3_model-correct.ipynb » pour le CNN initial ; « E3_best_model_optimized.ipynb » pour l'expérience d'optimisation et les visualisations Grad-CAM sur validation. La variante optimisée n'est pas retenue pour le test final en raison de ses résultats de validation inférieurs sur les métriques COVID prioritaires.

Traçabilité E4/M4 sur test : répertoire de résultats benchmark_final_test_E4_M4/ contenant notamment predictions_test_E4.csv, predictions_test_M4.csv, comparaison_finale_test_E4_M4.csv, rapport_binaire_test_E4.csv, rapport_binaire_test_M4.csv, rapport_multiclasses_test_M4.csv, matrice_confusion_test_E4.csv, matrice_confusion_binaire_test_M4.csv et matrice_confusion_multiclasses_test_M4.csv. Les noms sont repris des livrables documentés dans le rapport ; leur présence effective dans le dépôt doit être vérifiée avant diffusion des annexes.

Bibliographie indicative : COVID-19 Radiography Database (source du jeu de données, lien à compléter selon la source effectivement téléchargée) ; documentation TensorFlow/Keras et scikit-learn (bibliothèques utilisées). Les articles fondateurs de VGG16 et Grad-CAM ne sont pas présentés comme des lectures effectuées dans le cadre du projet.